

神经元模型

图灵测试

1956
达特茅斯会议

1969
感知机

1980s 专家系统

1998
CNN

2012
深度学习

2016
AlphaGo

2017
Transformer

2018
GPT

2022
ChatGPT

2023
Agent

2025
推理模型

2026
世界模型
多智能体

一部写给普通人的人工智能发展史——

每一个今天
都曾经是一个
没人相信的昨天

楔子

写这本书之前，有一桩事情我必须先说清楚。

我小时候读书，最怕的是数学和物理。不是我不肯用功，实在是因为那些公式太冷、太硬、太不讲情面。你看那教科书上，一行行推导工工整整，一个个定理铁板钉钉——好像这些东西是从天上掉下来的，跟活人没有半点关系。

后来读到一篇文章，让我对这件事有了完全不同的认识。那篇文章讲到一次世界大战时，一个叫拉莫尔的物理学家在战壕里写论文。炮弹就在头顶上飞来飞去，他却趴在泥地里推导他的公式。那一刻我突然明白——每一个公式背后，都有一个人；每一个人背后，都有一段故事。

那些故事里有血、有火、有汗、有泪。有深夜实验室里孤独的灯光，有学术会议上拍桌子的争吵，有二十岁少年一鸣惊人的狂喜，也有六旬老匠人一生心血付诸东流的悲凉。

若把这些故事写出来，那便是一部英雄传奇。

这部传奇里，有贫民窟里自学成才的天才少年，有战场上破译密码的数学奇才，有两个年轻人用数学画出大脑第一张草图的故事，有一本三百页的书把整个研究领域打入冷宫的公案，有三十年无人问津却在某个深夜突然找到突破口的狂喜，有一个人对着一台电脑说了一年“这不是笑话”的执拗。

这些故事串在一起，便是智能科学近八十年的兴衰沉浮——从1943年的第一个神经元模型，到如今能写诗作画、能自主行动的AI

大模型。

这部传奇的写法，我参照了前人的一个法子——把严肃的科学史，包裹在一层“通俗演义”的糖衣里。这法子不是我的发明。早在一百年前，就有人用章回体写过《科学演义》；后来又有梁衡先生，把数理化三大学科的故事讲得老少咸宜。

如今我斗胆效仿，把这个法子借用到人工智能科学上来。

书分十二回。从感知机的狂欢与寒冬，到专家系统的称霸与崩塌；从深度学习在黑暗中默默积蓄力量，到 Transformer 架构一夜之间改变世界；从 GPT 的千亿参数撑起人工智能的骨架，到 Agent 与 Skill 给大模型装上手脚和工具；再到如今最前沿的推理模型、世界模型与多智能体协同——这八十年的路，一步一个脚印，每一步都写满了人的执着与挣扎。

写这本书，只有一个愿望：当你翻开这本书时，你看到的不是一排排公式定理，而是一群活生生的人。他们跟你一样，会笑、会哭、会争吵、会迷茫。他们用一生追问“机器能否思考”这个问题——不是为了名，不是为了利，只是因为他们想知道答案。

这答案，至今还没完全找到。但正是这种“还没找到”的状态，让这个故事一直在继续。

这颗火种，至今未熄。

是为楔子。

第一回

贫儿避难窥天机 神童论道惊鸿儒

话说，这世上有三桩公案，纠缠了人类几千年，至今没个定论。第一桩，是天有多高；第二桩，是地有多厚。这两桩，倒还罢了——天高地厚，毕竟看得见摸得着，早晚能有个丈量的法子。唯独第三桩，最叫人头痛：人，到底是什么？

屈原在汨罗江畔问过，庄子在濠梁之上问过，苏格拉底在雅典街头问过。可惜问来问去，都不过是哲人的空谈。直到二十世纪中叶，这桩公案才突然有了转机——不是因为哲学家想通了，而是因为，人类造出了一种叫做“计算机”的东西。

这就引出了一个更要命的问题：机器，能像人一样思考吗？

一、

话说 1943 年，美国芝加哥。一个叫沃伦·麦卡洛克的神经学家，遇到了一个叫沃尔特·皮茨的数学天才。

这皮茨，是个奇人中的奇人。1923 年，他生在底特律的贫民窟，父亲是个锅炉工。旁人家的孩子若生在这般境遇，多半也就认了命，在街上厮混一生。可皮茨偏偏不。他把公共图书馆当成了避难所，躲在书堆里自学了希腊语、拉丁语、数学和逻辑学。

十二岁那年，他从书架上取下了罗素与怀特海合著的三卷本《数

学原理》——这部书号称“人类心灵的最高成就之一”，深奥难懂，即便是大学问家读起来也要费一番力气。可这个十二岁的少年，只用了三天便通读完毕。更绝的是，他还挑出了书中的几处错误，提笔就给罗素本人写了封信。

那罗素是何等人物？二十世纪最伟大的逻辑学家之一，诺贝尔文学奖得主。他收到一个美国贫民窟小孩的信，没有随手扔进纸篓，反而认真读了，还亲自回了信。他在信中写道：“你让我感到惊讶，一个十二岁的孩子能读懂这本书已是奇迹，而你居然还能看出错误。”罗素当即邀请皮茨去剑桥大学做他的研究生——此时的皮茨，连高中都还没毕业。

后来，皮茨辗转到了芝加哥大学，在那里遇见了麦卡洛克。麦卡洛克比他大二十多岁，一辈子都在琢磨一个问题：人脑里那数比繁星的神经元，到底是怎么工作的？他讨厌弗洛伊德那套“灵魂”、“潜意识”的说法——在他看来，理解意识，必须先从物理和数学入手。

而皮茨，正是那个能把生物学问题翻译成数学语言的人。

两人一拍即合。1943年，他们联名发表了一篇论文，提出了后来载入史册的“麦卡洛克-皮茨模型”——简称 M-P 模型。

这个模型讲了什么呢？用大白话来说，就是一句话：一个神经元，就像一个开关。

它接收从其他神经元传来的信号，每个信号有的重要、有的次要；当这些信号加起来超过某个“门槛”时，这个神经元就“兴奋”，向外发出信号；没超过，就“沉默”——

$$y = f\left(\sum_{i=1}^n \omega_i x_i - \theta\right)$$

就是这么个简单的数学式子，却证明了一个石破天惊的道理：由这样的神经元组成的网络，原则上可以计算世间任何逻辑问题。

这是人类第一次用数学的笔，画出了大脑的草图。

二、

就在 M-P 模型发表的同一年，大西洋彼岸，另一个天才也在做着一件惊天动地的事。

艾伦·图灵，1912 年生于伦敦。他 24 岁时就提出了“图灵机”的概念——那是一种抽象的计算模型，后来成为了现代计算机的理论基石。二战期间，他更是为盟军破译了德国的 Enigma 密码，历史学家普遍认为，这项工作至少让战争提前两年结束。

按理说，这样的功劳，足够他后半生躺在功劳簿上享清福了。可图灵偏不。他脑子里装着一个更大的问题。

1950 年，他在《心智》杂志上发表了一篇论文，题为《计算机器与智能》。文章一开头，他就把那个千古之问甩了出来：

“机器能思考吗？”

这问题太大了。大得没人知道该怎么回答。

于是图灵想了个巧妙的法子：他设计了一个“模仿游戏”。让一台机器和一个人分别躲在幕后，由评判员通过文字向他们提问。如果评判员分不清哪个是机器、哪个是人，那么这台机器就算具有了智能。

这便是著名的“图灵测试”——它巧妙地将“什么是思考”这个哲学难题，转化为了“什么表现算思考”这个可操作可衡量的技术问题。

如果说，麦卡洛克和皮茨给了人工智能一个可计算的“身体”；那么，图灵就给了它一个可判定的“灵魂”。

一个“身体”，一个“灵魂”——人工智能大厦的两根地基，在1943年到1950年这短短七年间，齐刷刷地立了起来。

三、

然而，桩子立起来了，却没几个人看得见。

M-P模型发表在生理学刊物上，数学家不看；图灵的论文发表在哲学刊物上，工程师不看。这三个学科——神经科学、数学、哲学——在那个时候，彼此之间隔着一堵厚厚的墙。谁也听不见谁在说什么。

真正把这堵墙推倒，让三个学科的人坐到一张桌子上的，是约翰·麦卡锡。

1956年夏天，这位达特茅斯学院的数学助理教授，拉着几位志同道合的朋友——包括马文·明斯基（哈佛大学的研究员）、克劳德·香农（信息论之父）和纳撒尼尔·罗切斯特（IBM工程师）——联名起草了一份提案，向洛克菲勒基金会申请了一笔7500美元的资助，计划在新英格兰的达特茅斯学院举办一场为期两个月的研讨会。

他们给这场研讨会取了一个响亮的名字——“人工智能夏季研讨会”。

这是人类历史上第一次，有人把“人工智能”这三个字正式写在了纸面上。彼时这四个人无论如何也不会想到，这个词对后世产生了多么深远的影响。

1956年6月18日，研讨会如期召开。到会的有三四十人，大多是二十出头的年轻人。他们来自数学、心理学、神经科学、工程学等不同领域——这些人原本可能一辈子都不会坐在同一间屋子里，如今却因为一个共同的信念聚在了一起：机器，或许可以拥有智能。

会上，纽厄尔和西蒙展示了“逻辑理论家”——第一个能自动证明数学定理的程序；塞缪尔展示了能自我对弈学习的跳棋程序。这些在现在看来幼稚得可笑的东西，在当时却如同闪电划破夜空一般惊醒了参会成员。

达特茅斯会议虽然没有达成什么统一的结论，但它做了一件最根本的事：它为这群散落在各学科的“孤勇者”找到了一个共同的家。从此，这门学科有了自己的名字——人工智能。1956年，也因此被公认为“人工智能元年”。

四、

写到这里，不妨把这三件事放在一起看一看。

1943年，M-P模型——给了机器一个可计算的“身体”。

1950年，图灵测试——给了智能一个可判定的“灵魂”。

1956年，达特茅斯会议——给了这门学问一个堂堂正正的“名分”。

从 1943 到 1956，不过短短十三年。皮茨从那个躲在图书馆里的贫儿，成长为能与麦卡洛克并肩的青年学者；图灵从一个破译密码的战争英雄，转变为叩问“机器能否思考”的哲学先知；麦卡锡和明斯基从两个年轻的研究员，成为了一个新兴学科的奠基人。

然而，所有英雄传奇的开端总是充满希望，而征途却遍布荆棘。这个刚满月的“人工智能”婴儿，即将迎来它漫长的第一个冬天。而那位被罗素誉为天才的少年皮茨，也将在二十多年后，因长期酗酒导致肝硬化，在剑桥的一间寄宿屋里孤独地死去。

人工智能的历史，从来不是一部一帆风顺的凯歌，而是一部写满了血与火、泪与汗的英雄史诗。

正所谓：

贫儿避难窥天机，神童评点惊鸿儒。

一师一徒开脑域，一测一问答千古。

达特茅斯夏风起，智能名分自此出。

莫道前路多霜雪，且看英雄踏征途。

欲知人工智能这襁褓中的婴儿，如何能历经两次寒冬而屹立不倒，最终长成参天大树，且听下回分解。

第二回

新闻界争说电子脑 明斯基一纸定生死

话说 1956 年达特茅斯会议之后，人工智能这面旗帜算是立起来了。可是，旗子虽在，旗杆底下却没几个人。这道理也简单——你“人工智能”口号喊得再响，人家得看见真东西才行。好比当年诸葛亮未出茅庐之时，名头再大，也不过是南阳一耕夫；非得等博望坡那把火烧起来，天下人才心服口服。

人工智能的“博望坡之火”，来得比人们预想的要快得多得多。

一、

1957 年，纽约州布法罗市，康奈尔航空实验室。

一个叫弗兰克·罗森布拉特的年轻心理学家，正在 IBM 704 计算机上跑一段程序。这台机器重以吨计，占了整整一间屋子，运算速度却还不如今天口袋里的一部手机。可就是在这台庞然大物上，罗森布拉特实现了一个改变历史的构想——感知机（Perceptron）。

这感知机是个什么东西呢？说白了，它就是麦卡洛克和皮茨那个 M-P 模型的具体实现。一个神经元，接收若干个输入信号，每个信号有不同权重；加权求和之后，超过某个阈值就输出“1”，否则输出“0”。就这么简单。

可就是这个简单的玩意儿，做了一件前所未有的事——它能“学

习”。

你给它看一组图片，告诉它哪些是苹果、哪些是香蕉。它就像个老老实实的学生一样，一次次地调整自己内部的那些权重参数——对了就巩固，错了就改正。反复若干次之后，你再给它一张从没见过的水果图片，它居然能自己判断出这是苹果还是香蕉。

在今天看来，这不过是幼儿园水平。可在 1957 年，这简直有如神迹。

二、

消息传出去，媒体全都疯了。

1958 年 7 月，美国海军研究办公室正式对外公布了罗森布拉特的发明，宣称这是“第一台能够拥有人类思想的机器”。《纽约时报》在头版刊出报道，标题赫然写着：《新海军设备边干边学》。

记者们蜂拥而至，争相目睹这台“电子大脑”的风采。报纸上连篇累牍，有的说它将来能看能听能说，有的预言十年之内机器将全面取代人脑。那股狂热劲儿，倒有点像前些年 ChatGPT 3 刚刚问世人们对其的追捧——历史啊，总是在不同时代翻出同样的浪花。

罗森布拉特本人倒还算清醒。他在论文里老老实实在地写道：感知机是一个“感知与识别自动机”，离真正的人类智能还差着十万八千里。可是，话虽这么说，全社会的期望已经被点燃了。政府和企业的研究经费，像潮水一样涌进了神经网络这个领域。

换做今天的话说，泡沫已经在吹了。

三、

然而，就在罗森布拉特和他的感知机被捧上神坛的同时，有一个人一直冷眼旁观。

此人正是马文·明斯基——达特茅斯会议上那个最年轻的参与者之一。明斯基和罗森布拉特，本是同一代的人物。1956年达特茅斯会议上，两人还曾同堂讨论。可此后，两人却走上了截然不同的道路。

罗森布拉特一头扎进了“连接主义”——相信智能来自于大量神经元的连接与学习。明斯基则坚定地站在“符号主义”一边——认为智能的本质是符号的逻辑运算，而不是神经元的统计学习。

这两个流派的分歧，好比当年儒学内部的理学与心学——一个强调外在的格物致知，一个强调内在的顿悟明心。你说谁对谁错？在那个年代，谁也说不清。

但明斯基心里清楚一件事：罗森布拉特的感知机，有致命的缺陷。

四、

1969年，明斯基与同事西摩·帕尔特合著了一本书，书名就叫《感知机》。

这本书有308页，里面密密麻麻全是数学证明。而全书的核心结论，用一句话就能说清：单层感知机，连最简单的“异或”（XOR）问题都解决不了。

什么叫“异或”问题？举个最简单的例子。假设有两个输入，每

个输入要么是 0 要么是 1。如果两个输入相同，输出 0；如果两个输入不同，输出 1。就这么个简单的逻辑——小学一年级的孩子都能理解——可罗森布拉特的感知机，无论如何调整权重，都算不出来。

明斯基在书中用严谨的数学证明：单层感知机只能解决“线性可分”的问题。什么叫线性可分？就是你能在平面上画一条直线，把两类数据干干净净地分开。而“异或”问题，你画不出一条直线——它需要曲线，或者更复杂的结构。

换句话说，感知机只能解决最最简单的那一类问题。稍微复杂一点的，它就抓瞎了。

这个结论本身，其实没什么大惊小怪的——任何一种技术都有其局限性和适用范围。可问题在于，这本书出版的时间点太要命了。

五、

你想啊，此前十年，媒体把感知机吹上了天，政府和企业的钱大把大把地投了进去。如今，人工智能领域最权威的学者之一，出了一本数学专著，白纸黑字地把媒体、政府和企业的脸打的啪啪作响：你们追捧的那个劳什子“电子大脑”，连个幼儿园的逻辑题都做不出来！

这相当于什么？相当于你正吃着满汉全席，突然有人告诉你——这桌菜全是馊的。

风向一夜之间变了。

资助机构纷纷撤资，论文投稿无人问津，研究生们纷纷转行。那些曾经在报纸上把感知机捧上天的记者们，又转过头来写起了“人工

智能的骗局”。从 1970 年代初期开始，神经网络研究几乎被彻底 shut down，这一冷，就是将近十五年。

这段时期，后来被人工智能史学家称为“第一次 AI 寒冬”。

六、

我们回过头来看这段历史，不免要问一句：明斯基那本书，当真判了神经网络的死刑吗？

其实不然。明斯基和帕尔特在书中证明的，仅仅是单层感知机的局限。他们自己也提到了一个可能性——如果在输入层和输出层之间增加一层所谓的“隐藏层”，也许就能解决异或问题。只不过，他们在书中猜测，即便加了隐藏层，恐怕也找不到有效的训练方法。

这个猜测，后来被证明是错的。但那已经是十几年后的事了。

公允地说，明斯基那本书的学术价值不容否认——它用数学的严谨，划清了感知机的能力边界。可它的历史影响，却远远超出了学术范畴。它成了一把舆论的刀子，把整个刚刚兴起的神经网络研究捅了个对穿。

这让人想起一句老话：木秀于林，风必摧之。感知机被捧得越高，摔得就越惨。泡沫吹得越大，破灭时的声响就越惊人。罗森布拉特本人，也在 1971 年——就在他的研究被全面否定的两年后——因溺水意外去世，年仅 42 岁。

七、

写到这里，我们不妨把这十几年的兴衰放在一起看一看。

1957 年，感知机诞生——媒体欢呼“电子大脑”问世。

1958 到 1968 年，泡沫膨胀——经费如潮水般涌入，期望如气球般吹大。

1969 年，明斯基出书——一盆冰水，浇了个透心凉。

1970 年代，寒冬降临——神经网络研究几乎绝迹。

从狂欢到寒冬，不过十二年。这十二年间，人们先是把一个简单的线性分类器捧成了“万能大脑”，然后又因为发现它不是万能的，便把它整个儿扔进了垃圾堆。

这两种态度，其实犯的是同一个错误：非此即彼，走极端。

可科学的发展，从来不是一条直线。它遵循马克思主义哲学：如同一条蜿蜒的河流，有时汹涌，有时干涸，有时甚至倒流——但只要你肯耐心等待，它终究会找到自己的出路。

感知机的故事，到这里暂时告一段落。但神经网络的火种并没有完全熄灭——在世界的某个角落，还有几个不甘心的年轻人，正在黑暗中摸索着前进。他们不知道，十几年后，一种叫做“反向传播”的算法将会重新点燃这把火；他们更不知道，三十几年后，一个叫做“深度学习”的东西将会席卷整个世界。

只是此刻，寒夜正长。

正是：

电子大脑惊天下，媒体争说赛神仙。

孰料斯基一书出，异或门前竟翻船。

经费散尽人踪灭，长夜漫漫十五年。

莫道火种今已绝，且看地下有暗泉。

欲知这神经网络如何在寒冬中苟延残喘，又是哪几位孤勇者在不被看好的年代里悄悄埋下了复兴的种子，且听下回分解。

第三回

专家系统称霸江湖 知识工程终成幻梦

话说上一回讲到，感知机被明斯基一本书判了死刑，神经网络研究从此一蹶不振，进入了漫长的第一次寒冬。整个 1970 年代，但凡跟“神经元”、“连接主义”沾边的论文，投出去便如石沉大海。研究生们纷纷改行，教授们纷纷转向，曾经热火朝天的实验室里落满了灰尘。

可天下事，从来是“东边日出西边雨，道是无晴确有晴”。神经网络这一支熄了火，另一支却悄悄烧了起来。

这一支的旗号，叫做符号主义——主张智能的本质是符号的逻辑运算。明斯基是这一派的悍将，但他不是一个人在战斗。在他身后，还站着一个比他更执着、更务实的年轻人。

此人便是爱德·费根鲍姆。

一、

话说这费根鲍姆，1936 年生于新泽西州。他从小聪慧过人，一路读到了卡内基理工学院。在那里，他遇见了对他影响最大的两位老师——赫伯特·西蒙和艾伦·纽厄尔。

这西蒙和纽厄尔，正是 1956 年达特茅斯会议上展示“逻辑理论家”的那两位。他们坚信：人类的智能，本质上就是符号的操纵和运

算。你把知识写成一条条的“规则”—— IF A THEN B ——机器只要照着这些规则一条条推下去，就能像人一样思考。

费根鲍姆从这两位老师那里，学到了一个朴素而坚定的信念：智能的关键，不在于神经元的连接方式，而在于知识本身。你给机器装进多少知识，它就拥有多少智能。

这句话后来成了“知识工程”的纲领——也是整个符号主义流派最响亮的宣言。

1965 年，费根鲍姆来到斯坦福大学，在这里开始了他毕生最重要的工作。他和一位名叫约舒亚·莱德伯格的遗传学家合作，做了一个叫做 DENDRAL 的系统。

这个系统是干什么的？简单来说，它帮化学家分析质谱数据，推断未知化合物的分子结构。这在当时是极其耗时的工作——一个经验丰富的化学家，拿到一张质谱图，要翻半天参考书才能猜出个大概。而 DENDRAL，只要输入数据，几分钟就能给出几种可能的分子结构，还附带“置信度”评分。

这是人类历史上**第一个成功的专家系统**——一个把专家的知识 and 推理规则“编码”进计算机的程序。

消息传出去，学术界震动。不是因为 DENDRAL 做了一件多么复杂的事，而是因为它证明了一件事：只要把足够多的专业知识写成规则输进电脑，电脑就能像个真正的专家一样工作。

这不正是人们梦寐以求的“人工智能”吗？

二、

DENDRAL 的成功，让费根鲍姆声名鹊起。可他心里明白，这还远远不够。化学质谱分析毕竟是个小领域，他要做一件更大的事——做一个人人能用、能解决实际问题的通用专家系统。

1972 年，他的团队启动了另一个项目，取名 MYCIN。

MYCIN 是个什么系统呢？它是个“医生”——专门诊断血液感染和脑膜炎的医生。医生看病是怎么看的？先问症状，再做检查，然后根据检查结果和自己的临床经验，判断病人得了什么病，该用什么药。MYCIN 把这个过程原封不动地复制了下来。

你在终端前输入病人的症状和化验结果，MYCIN 就开始“思考”。它内部有数百条规则——

形如：IF 病人有发热 AND 白细胞计数高于正常指标

THEN 可能存在感染

——一条一条地进行匹配、推理、判断，最后给出诊断意见和治疗方案。

更绝的是，MYCIN 还会解释自己的推理过程。你问它“为什么推荐这个抗生素”，它会给你列出一串规则链——“首先，我发现病人有 A 症状；根据规则 12，这指向 B 可能；于是我用规则 23 进一步判断……”一套一套的，说得头头是道。

要知道，这是在 1970 年代中期。那时候全世界的计算机加起来，还没有今天一部手机算得快。可就是在那样简陋的条件下，一群斯坦福的年轻人，做出了一个能像医生一样诊断疾病、还能跟人解释为什

么这么诊断的系统。

你能想象当时引发了多大的轰动吗？简直有如核弹爆炸，眩晕瘫坐。

三、

1970 年代末到 1980 年代初，是专家系统的黄金时代。

大公司们像发现了金矿一样，争先恐后地组建团队，开发专家系统。DEC 公司用专家系统帮计算机配置硬件——“XCON 系统”，每年节省数百万美元。通用电气、杜邦、波音——但凡数得上号的大企业，都在搞自己的专家系统。政府和军方更是慷慨解囊，经费像流水一样又涌进了这个领域。

泡沫又在吹了。

费根鲍姆和他的同事们，看着这个由自己点燃的火苗烧成燎原之势，心里自然是高兴的。可高兴之余，他又隐隐有些不安。有一回，他在一次公开演讲中，对着满堂的工业界听众说了一段话：

“各位，我感谢你们的热情。可我必须提醒诸位——专家系统不是神。它只能解决那些‘规则明确、范围狭窄’的问题。你让 MYCIN 看病，它看得不错；可你让它顺便帮你看肝功或者做个外科手术，它立刻就会傻眼。”

这话说得很清醒。可惜，清醒的话没人爱听。

那时候的商界，满耳朵听到的都是诸如“人工智能将要取代专家”、“计算机即将拥有博士级别的智力”一类的话语。那些天花乱坠的报

道和演讲，把专家系统吹得无所不能。费根鲍姆那几句提醒，早就被淹没在了了一浪高过一浪的欢呼里。

四、

泡沫吹得最大的时候，往往离破碎最近。

到了 1980 年代中后期，问题一个一个地冒了出来。

首先是**知识获取**的瓶颈。一个专家系统要做得像模像样，至少需要成百上千条规则。这些规则从哪里来？从一个一个地访谈行业专家那里来。你得把专家的脑子“掏空”，把那些隐性的、直觉的、难以言说的经验，一条一条地翻译成“IF...THEN...”的形式。

这活儿说起来简单，做起来苦不堪言。费根鲍姆的团队当年开发 MYCIN，光是抽取规则这一项，就用掉了无数个日日夜夜。一个顶尖的医学专家坐在那里，被一群程序员反复追问：“这种情况下你为什么这样判断？”追问到后来，专家自己都糊涂了——“我判断的时候，自己都没想明白是怎么判断的，你让我怎么给你写规则？”

其次是**可维护性**的问题。一个专家系统做出来的时候好好的，可现实世界在变。新的知识不断出现，旧的规则不断过时。今天建的规则库，三个月后就可能有三分之一不适用了。可修改规则库是个极其危险的工作——你改了一条，说不定就影响了另外几十条的连锁推理。牵一发而动全身，修一次比新建一次还费劲。

最致命的是**脆弱性**。专家系统只能在它那个“小圈圈”里转。一旦输入的是一条规则库里没有覆盖到的“边缘情况”，系统立刻就会

——不是答错，而是毫无预兆地给出一个离谱的答案，还自信满满地告诉你：“我的推理完全正确。”

用大白话来说：它只知道自己知道的，完全不知道自己不知道什么。

后来在大模型风靡全球的时候，人们在给这种现象起了一个名字：模型幻觉（Model Hallucination）。

不止模型，人也有幻觉。

五、

到了 1980 年代末，那把火终于烧到了尽头。

政府开始审计那些投入巨大的 AI 项目，发现大部分专家系统要么尚未完工，要么完工了但压根没法用。企业开始算账——投入几百万美元开发的系统，省下来的那点人力成本，连开发费用的零头都不够。当年那些热情洋溢的报道，全变成了质疑和嘲讽的刀枪。

经费如同退潮一般退了回去。实验室关门的关门，团队解散的解散。那些曾经把专家系统捧上天的公司，一夜之间删除了所有相关文件，仿佛这场狂欢从来没有发生过。

这一冷，比第一次寒冬来得更为彻底。因为这一次，不光是学术界没了经费，连工业界也全面撤离。从 1980 年代末到 1990 年代中期，人工智能研究再次进入冰河期——后来史称“第二次 AI 寒冬”。

费根鲍姆目睹了自己亲手点燃的火苗被一盆冷水浇灭。那位曾经

意气风发的“知识工程之父”，坐在斯坦福的办公室里，对着满墙的研究报告和项目计划书，沉默了很久。

可他最终没有绝望。多年后他回忆起那段日子时说了这样一句话：

“我们当年的错误，不是把目标定得太高，而是把实现的路径想得太简单了。‘知识工程’这个方向没有错——它只是需要更多的时间，更好的技术，以及几代人的接力。”

六、

回过头来看这两次寒冬，我们或许能品出一些味道来。

第一次寒冬，是因为人们把感知机捧成了“万能大脑”，结果发现它连道幼儿园题都解不出来。第二次寒冬，是因为人们把专家系统当成了“万能专家”，结果发现它在圈子里还行，出了圈子就抓瞎。

两次寒冬，病因其实是同一个：期望过高，摔得太重。也就是前文埋下的伏笔：

不止模型，人也有幻觉。人的幻觉比模型的更重。

可这两次寒冬还有另一个共同点：火种并没有彻底熄灭。第一次寒冬时，罗森布拉特的感知机虽然被打入冷宫，但“连接主义”的火种没有绝迹——有人还在角落里默默研究神经网络。第二次寒冬时，专家系统虽然大厦崩塌，但“知识工程”的火种也没有绝迹——它后来以另一个名字重生，叫做“知识图谱”。

这两颗火种，一个在暗处积蓄力量，一个在明处不断迭代。几十年后，它们终将汇成一道洪流，推动人工智能走进一个全新的时代。

只是此刻，寒夜正长。1989 年的冬天尤其冷。

可就在这个冬天里，有一个叫**杨立昆**的法国年轻人，刚刚在贝尔实验室发表了一篇论文。论文里，他提出了一种叫做“卷积神经网络”的东西。他给它取了个名字——LeNet。

这个 LeNet 后来做了一件在当时看来微不足道、在后来看来惊天动地的事：它认出了手写邮政编码。

没人知道，这颗微小的火种，将要在二十年后掀起一场何等壮阔的革命。

正是：

专家系统称霸日，知识工程辉煌时。

一朝泡沫随风散，万千规则化成尸。

两次寒冬同因果，只缘期望高过天。

莫道火种今已灭，且看暗处起微烟。

欲知这卷积神经网络如何在无人问津的岁月里默默生长，又是如何一战成名，从此开启深度学习的新纪元，且听下回分解。

第四回

猫咪开天目启新程 福岛筑神机传薪火

话说上一回讲到，专家系统的大厦轰然倒塌，人工智能领域第二次陷入漫漫长夜。可这世上总有一类人，越是无人问津的时候，他们越不肯撒手——就像冬天里埋在地下的种子，外面冰天雪地，里面却在悄悄发芽。这一次，发芽的地方不在美国，也不在欧洲，而在东亚——日本。

这颗种子，叫做“卷积神经网络”。它的故事，得从一只猫说起。

一、

1962年，美国哈佛大学。两位神经生物学家——休伯尔（David Hubel）和威泽尔（Torsten Wiesel）——正在做一组实验。他们在猫的脑袋上开了一个小窗，将电极插入猫的视觉皮层，然后用幻灯机向猫展示各种图形——横的、竖的、斜的、动的、静的。

实验结果令人震惊：猫的大脑皮层里，不同的神经细胞对不同的图形做出反应。有的细胞只对横线敏感，有的只对竖线敏感，有的只对某个角度的斜线敏感。更妙的是，这些细胞是分层次的——低层的细胞感知最简单的边缘信息，高层的细胞则把这些边缘信息组合成更复杂的图形。

打个比方：你看到一张人脸，并不是某一个神经元认出了这张脸。

而是无数个低层神经元先认出了眼睛、鼻子、嘴巴的边缘，然后更高层的神经元把这些零件拼在一起，最后才得出“这是一张脸”的结论。

休伯尔和威泽尔因为这个发现，在 1981 年获得了诺贝尔生理学或医学奖。可他们大概想不到，这个关于猫的实验，二十年后会启发一个日本人，造出改变世界的算法；四十年后，又会启发一个法国人，彻底改写人工智能的历史。

这个日本人，叫福岛邦彦。

二、

福岛邦彦，1935 年生于日本。跟皮茨一样，他小时候家境也不宽裕——可这孩子偏偏对电子技术着了迷。一路读到了京都大学，拿了电气工程博士学位。1965 年，他加入了一个研究视觉和听觉信息处理的小组，开始琢磨一个问题：生物的大脑到底是怎么识别东西的？

休伯尔和威泽尔那篇关于猫的论文，他读了。读完之后，一个念头冒了出来——既然生物的视觉系统是多层次的，每一层做不同的事，那我能不能在计算机里也搭一个这样的“多层”网络？

1979 年，福岛邦彦发表了一篇论文，提出了一个叫做“Neocognitron”的模型——中文译作“神经认知机”。这个名字起得好——“神经”说的是它模仿大脑，“认知”说的是它能识别东西。

这个 Neocognitron 长什么样呢？它有两类层，交替排列。一类叫

“S 层”，对应休伯尔实验里那些对简单边缘敏感的细胞；另一类叫“C 层”，对应那些对复杂图形敏感的细胞。S 层提取特征，C 层做“池化”——也就是把图像缩小、压缩，让网络对位置不那么敏感。一层 S，一层 C；再一层 S，再一层 C。一层一层往上堆，每一层都在前一层的基础上提取更复杂的特征。

今天我们把这种结构叫做卷积层和池化层——而在 1980 年，福岛邦彦已经在论文里把它们写得清清楚楚了。这是人类历史上第一个真正意义上的卷积神经网络。

可惜，这颗种子撒下去，没长起来。

原因有两个。第一，福岛的训练方法是无监督的——网络自己学自己的，没人告诉它对错。第二，也是更要命的——那时候还没有反向传播算法。网络内部的参数调不了，学习能力就上不去。Neocognitron 能认几个简单的手写数字，但也就到此为止了。

福岛邦彦在 1980 年种下了一棵树的苗，可这棵树要长大，还得等一场雨。这场雨，六年后才下。

三、

1986 年，英国《自然》杂志上刊登了一篇论文，标题叫《通过反向传播误差来学习表征》（Learning representations by back-propagating errors）。作者有三个人：大卫·鲁梅尔哈特、杰弗里·辛顿和罗纳德·威廉姆斯。

这篇论文只有短短几页，却像一颗炸弹扔进了沉寂多年的神经网络

络领域。

它解决了什么问题呢？我们得回头看一看。

还记得第二回里那个让感知机翻车的异或问题吗？明斯基在1969年就指出来了——单层感知机算不出异或。可他也提了一句：如果在输入和输出之间加一层“隐藏层”，也许就能解决。问题在于，加了隐藏层之后，怎么训练？你告诉它“答案错了”，可它不知道错在输入层、隐藏层还是输出层——每一层的参数都在影响最终的结果，这笔账算不清楚。

反向传播算法就是来算这笔账的。

它的核心思想，用大白话说就是：把最后的错误，一层一层地往回“传”。好比一个工厂，生产出来的产品不合格——你先罚最后一关的工人，再罚倒数第二关的，再罚倒数第三关的……一直追溯到第一关。每一层都知道自己该负多少责任，该调整多少参数。

有了这个算法，多层神经网络终于可以训练了。明斯基当年那个“加了隐藏层恐怕也找不到训练方法”的猜测，被辛顿这篇论文彻底推翻了。

可问题又来了——反向传播虽然好用，但神经网络这个领域，已经被明斯基那本书打入了冷宫十几年。学界的偏见根深蒂固：神经网络不行，别浪费时间。

所以，这篇发表在《自然》上的论文，虽然引用量后来冲上了将近一万六千次，可在当时，响应者寥寥无几。大多数人看了，点点头，翻过去，继续做别的。

但有一个人，读了这篇论文之后，眼睛亮了。

四、

这个人叫杨立昆（Yann LeCun）——法国人，1960 年生于巴黎附近。1987 年，他在巴黎第六大学拿到了计算机科学博士学位，然后去了多伦多大学，在杰弗里·辛顿手下做博士后。没错，就是那个发表了反向传播论文的辛顿——杨立昆是他的学生。

杨立昆早就读过福岛邦彦关于 Neocognitron 的论文。他心里一直有个想法：福岛那个结构是对的——S 层和 C 层交替、层层递进——但训练方法是错的。如果把福岛的结构和辛顿的反向传播结合起来呢？

1988 年，杨立昆加入了一个地方——AT&T 贝尔实验室。这个地方你要记住，因为在后来的故事里，它还会反复出现。贝尔实验室是全世界最顶尖的工业研究机构之一，出过九位诺贝尔奖得主。杨立昆在这里，终于有了足够的资源和数据，去实现他的想法。

他拿到了美国邮政局提供的一批数据——9298 个从信封上扫描下来的手写邮政编码数字。这些数字歪歪扭扭、大小不一、乱七八糟——正是测试神经网络的最好材料。

1989 年，杨立昆发表了一篇论文，第一次用反向传播成功训练了一个卷积神经网络。他把这个网络用在了手写数字识别上——效果惊人。1990 年，他和贝尔实验室的同事们又发表了升级版，在邮政数据上的错误率降到了 1%，拒绝率约 9%。

后来人们把这个网络叫做“LeNet”——取自他的名字 LeCun。

你可能觉得 1% 的错误率没什么了不起。可你要知道，那可是 1990 年——计算机的速度还不到今天一部手机的万分之一。在那个年代，能让机器认出手写数字，并且错误率只有 1%，这已经近乎神迹了。

更了不起的是，LeNet 后来真的被用在了实际生活中——美国邮政系统用它来自动分拣信件。这是人类历史上第一个被大规模商业部署的神经网络模型。

三颗火种，终于汇成了一道光。

五、

写到这里，我们不妨把这三件事串起来看一看。

1962 年，休伯尔和威泽尔拿猫做实验——发现了视觉皮层是分层次的。

1980 年，福岛邦彦提出 Neocognitron——第一次把“卷积”和“池化”写进了神经网络。

1986 年，辛顿等人发表反向传播算法——让多层神经网络终于能被训练。

1989 到 1990 年，杨立昆在贝尔实验室研发出 LeNet——把三样东西合在一起，造出了能用的卷积神经网络。

可即便是 LeNet 这样里程碑式的成果，在当时也没能掀起多大的浪花。杨立昆在贝尔实验室的走廊里走，同事们见了他，多半只是点点头，转身继续忙自己的事。神经网络这个领域，已经被冷落了太久。

一篇论文、一个成果，改变不了整个学界的成见。

此后的将近二十年里，卷积神经网络就像一条暗河——在地底下默默地流，偶尔露出地面，又很快被淹没。福岛邦彦在 1980 年撒下的那颗种子，要等到 2012 年——整整三十二年后——才会长成一棵参天大树。

但那是后话了。此刻，且让我们把目光投向另一个方向——在那个同样寒冷的年代里，还有一群人，正在用一种完全不同的方法，试图让机器学会“看”世界。他们的故事，我们下一回再讲。

正是：

猫咪开眼窥天机，福岛筑机启新程。

反向传播降甘雨，贝尔实验室里耕。

三颗火种终相汇，LeNet 问世世人惊。

莫道暗河无人见，且看深流待春生。

欲知这卷积神经网络如何在无人问津的地下暗河中默默流淌二十载，又是如何在一夜之间破土而出、声震人间，且听下回分解。

第五回

三剑客暗夜守孤灯 一火种深埋待春生

话说上一回讲到，杨立昆在贝尔实验室做出了 LeNet，手写数字识别准确率高达 99%，甚至被美国邮政系统用在了实处。可就是这么个了不起的成果，也没能掀起多大的浪花。贝尔实验室的走廊里，同事们见了杨立昆，多半只是点点头，转身继续忙自己的事——仿佛他做的不过是件无关紧要的小玩意儿。

杨立昆后来回忆那段日子，说了一句让人心酸的话：“从 1995 年到大概 2002 年，有六七年的黑暗期，没人研究这个。有一段时间，根本不可能发表关于神经网络的研究论文，因为学术界已经完全失去了兴趣。”

这一冷，比前两次寒冬来得更寂静。前两次好歹还有过狂欢——感知机被媒体捧上天过，专家系统被企业争相抢购过。可这一次，连狂欢都没有了。整个领域悄无声息地凉了下去，像一堆无人添柴的炭火，只剩下几点微弱的火星。

可就是这几颗火星，撑过了最漫长的夜。

一、

先说杰弗里·辛顿。

1947 年，辛顿生于英国伦敦一个显赫的科学家家族。他的曾祖

父是著名数学家乔治·布尔的孙子，他的父亲是个药理学家，家里长辈里有好几个英国皇家学会会员。用中国话说，这就是“书香门第”——按常理，他应该在剑桥或牛津读个学位，然后顺理成章地成为某个领域的权威。

可辛顿偏偏走了一条完全不同的路。

1970年代，当别人都在做专家系统赚大钱的时候，他在研究神经网络；1980年代，当反向传播论文发表却无人响应的时候，他还在研究神经网络；1990年代，当整个学术界都把神经网络当成死路一条的时候——他仍然在研究神经网络。

那时候，多伦多大学计算机系私下流行着一句对新生的警告：“不要去辛顿的实验室。”因为去了那里，就意味着你要把职业生涯押在一个被主流宣判了死刑的方向上——论文发不了，工作找不到，前途一片渺茫。

辛顿不为所动。据说他有一种特殊的自我激励方法——每周大吼一次：“我发现大脑是怎样工作的啦！”这个习惯，他坚持了几十年。在神经网络论文几乎发不出来的那段时间，他硬是写了两百多篇研究论文。没人看？没关系。发不了？没关系。他只是在用这种方式告诉自己：我还在做，我没有放弃。

有一次接受采访，他说了这样一段话：“我知道我们的方向是对的，但我不知道什么时候才能证明这一点。有时候我想，也许我要在退休之前都无法看到这一天。”

说这话的时候，他的声音里没有怨气，只有一种平静的、近乎固

执的等待。

但他不知道，这一天很快就要来了。

二、

花开两朵，各表一枝。再说杨立昆。

杨立昆 1960 年生于巴黎附近。他父亲是个航空工程师，母亲是个药剂师。这个家庭没什么学术背景，但杨立昆从小就表现出对科学的兴趣——他后来回忆说，自己十几岁时就在笔记本上画“模拟大脑的机器”的设计图。

1987 年，他在巴黎第六大学拿到了计算机科学博士学位，然后去了多伦多大学，在杰弗里·辛顿手下做博士后。没错，就是那个发表了反向传播论文的辛顿——杨立昆是他的学生。

1988 年，杨立昆加入 AT&T 贝尔实验室。这个地方你要记住，因为在后来的故事里，它还会反复出现。贝尔实验室是全世界最顶尖的工业研究机构之一，出过九位诺贝尔奖得主。杨立昆在这里，终于有了足够的资源和数据，去实现他的想法。

1989 年，他发表了那篇改变历史的论文——用反向传播成功训练了一个卷积神经网络，也就是后来人们熟知的 LeNet。在邮政数据上的错误率降到了 1%，被美国邮政系统用于自动分拣信件。

这是人类历史上第一个被大规模商业部署的神经网络模型。

可问题是——学术界依然不买账。

1996 年，AT&T 公司拆分，贝尔实验室被一分为二。杨立昆的团

队失去了原本还算充裕的经费支持。更糟糕的是，他在 1990 年代末做的那套支票识别系统，虽然占据了美国大约 10% 的市场，却被研究界解读为“在一个特定的小问题上有效”，而不是“深度学习是一种通用的方法”。

这就像什么呢？就像一个工匠花了几十年打造了一把绝世好刀，可别人看了一眼说了一句：“切水果倒是挺快。”然后转身就走了。

杨立昆后来离开贝尔实验室，去了纽约大学。在那里，他的实验室很小，经费很少，愿意跟他干的学生也不多。可他没有转行。他继续做卷积神经网络，继续在几乎没人关注的角落里，默默地推进着自己的研究。

有一年冬天，他站在纽约大学的办公室里，看着窗外曼哈顿的灯火，对他的学生说了一句话：“我们做的这个东西，将来会改变世界。只是现在，还没有人知道。”

三、

还有第三个人——约舒亚·本吉奥。

如果说辛顿是深度学习的“哲学奠基人”，杨立昆是“工程实践的先驱”，那么本吉奥就是“自然语言处理方向的拓荒者”。

本吉奥 1964 年生于法国，比辛顿年轻了十七岁。他从小在巴黎长大，在麦吉尔大学拿了博士学位，然后留在了加拿大，在蒙特利尔大学任教。

1990 年代，当别人都在做图像识别的时候，他却一头扎进了一

个更难的方向——用神经网络处理语言。

语言这个东西，比图像麻烦得多。一个词的意思，往往取决于几十个词之前的上下文。而当时的循环神经网络，处理长序列时有个致命的毛病——“梯度消失”。越往后的信息，传着传着就没了。

打个比方：你在一个很长的走廊里喊一句话，声音会越来越小。等传到走廊尽头的时候，已经听不清你在喊什么了。循环神经网络处理长句子时就是这个状态——第一句话的信息，传到句尾的时候，已经衰减得差不多了。

本吉奥花了很长时间在这个问题上。他试过很多种方法，但效果总是不理想。有很长一段时间，他的论文投出去，审稿人的回复几乎都是同一句话：“这个方法没有意义，神经网络不适合处理语言。”

可本吉奥没有放弃。2003 年，他发表了一篇论文，提出了“词嵌入”的核心思想——用一串连续的数字向量来表示词语，让意思相近的词在数字空间里也彼此靠近。

这个思想十年后成了整个自然语言处理领域的基础。可在 2003 年，这篇论文同样没翻起什么浪花。

本吉奥后来回忆说：“那时候，我们三个人——辛顿、杨立昆和我——偶尔会通电话，互相打气。每次通话结束的时候，我们都会说同一句话：“坚持下去，方向是对的。”

坚持，是他们唯一的武器。

四、

这三个人，分别在三座城市——多伦多、纽约、蒙特利尔。三种国籍——英国人、法国人、法国人（后入加拿大籍）。三种研究风格——一个偏哲学思辨、一个偏工程实践、一个偏数学理论。可他们有一个共同点：都在做一件被大多数人认为没有前途的事。

2004 年，事情出现了一丝转机。

辛顿从加拿大高等研究院（CIFAR）拿到了每年 50 万美元的经费。这笔钱跟当年专家系统动辄几百万美元的投入相比，简直少得可怜。可辛顿用它做了一件关键的事——他把杨立昆、本吉奥，还有一批来自计算机、生物学、神经科学、物理学和心理学各个领域的人，组织成了一个叫做“神经计算与自适应感知”的项目组。

这个项目组没有豪华的实验室，没有铺天盖地的宣传。他们只是定期聚在一起，讨论同一个问题：神经网络这条路，到底走不走得通？

就是在这个项目组里，辛顿、杨立昆、本吉奥三人形成了一个稳固的“铁三角”——彼此知道对方在做什么，偶尔协作，共同成为这个领域在漫长黑暗时期的三根顶梁柱。

二十年后，他们三人将共同获得图灵奖——计算机科学界的最高荣誉，被世人尊称为“深度学习三教父”。可在那时，他们不过是三个在无人问津的角落里，点着孤灯苦读的守夜人。

辛顿的办公室在多伦多，墙上贴满了神经网络结构图，窗外是安大略湖的暮色。

杨立昆的实验室在纽约，桌上堆满了论文草稿，窗外是曼哈顿的天际线。

本吉奥的书房在蒙特利尔，电脑屏幕上跳着一行行代码，窗外是圣劳伦斯河的冰封。

三座城市，三个人，一个共同的方向。

他们不知道春天什么时候会来。他们只是相信，春天会来。

五、光有算法还不够：算力和数据的种子正在发芽

然而，三教父守住了算法的火种，可光有算法还不够。要让神经网络真正强大起来，还需要两样东西：算力和数据。

这两样东西的种子，也正在无人注意的角落里悄悄发芽。

先说算力。2008 年，斯坦福大学的一个叫吴恩达的华裔年轻学者，正在做一个大胆的实验。他用两块 NVIDIA GeForce GTX 280 显卡——当时市面上最强的 GPU——去训练一个具有 1 亿个参数的神经网络模型。结果让人目瞪口呆：GPU 的并行计算速度是 CPU 的 70 倍。原本需要几个星期的计算，一天就干完了。

吴恩达后来回忆这个实验时，只说了一句话：“我意识到，神经网络不是算不动，是以前用的工具不对。”

再说数据。2007 年，一位叫李飞飞的华裔女科学家，在普林斯顿大学正式启动了一个疯狂的项目——ImageNet。她打算构建一个包含 22000 个类别、2000 万张图片的图像数据集，把真实世界的模样装进去。

这个想法听起来简单，做起来却难如登天。她借助亚马逊的众包平台，发动了来自 167 个国家的 49000 名标注员，日以继夜地给图片打标签。2009 年，ImageNet 正式发布。1500 万张图片，22000 个类

别。这是人类历史上最大的图像数据集——没有之一。

可发布之后，没什么人理睬。

算法有了，引擎有了，燃料有了。只差一个人，一把火。

这个人 and 这把火，将在 2012 年那个秋天出现。但那是下一回的事了。

此刻，且让我们记住这三个守夜人的名字——杰弗里·辛顿、杨立昆、约舒亚·本吉奥。

他们是这场漫长黑暗里最孤独也最坚定的三个人。

正是：

多伦多夜守孤灯，纽约城中做匠人。

蒙特利尔向死生，三城三子一条心。

每周一吼惊四壁，廿载论文无人问。

莫道寒冬长似夜，且看春雷破土声。

欲知这火种如何燃成燎原之势，且听下回分解。

第六回

百万张图片喂神经 大力出奇迹震群雄

话说上一回讲到，辛顿、杨立昆、本吉奥三人在漫长的黑暗岁月里，守着神经网络这颗火种，一等就是二十年。可光有算法还不够——要让神经网络真正强大起来，还需要两样东西：算力和数据。

这两样东西，在 2012 年之前，一直像两座大山一样压在神经网络研究者的头上。没有算力，再好的算法也只能在纸上画画；没有数据，再精巧的网络也练不出真本事。

而打破这两座大山的人，一个叫吴恩达，一个叫李飞飞。

一、

先说算力。

2008 年，斯坦福大学。一个叫吴恩达的华裔年轻学者，正在做一个大胆的实验。

吴恩达 1976 年生于英国，父亲是香港人，母亲是新加坡人。他从小在香港长大，后来去美国读书，在卡内基梅隆大学拿了博士学位，2002 年加入斯坦福大学任教。他的研究方向一直是机器学习，但这些年他越来越觉得不对劲：神经网络的理论已经越来越成熟，可训练一个像样的模型需要的时间太长了——长到让人怀疑这条路到底走不得通。

问题出在哪？出在计算工具上。

长期以来，训练神经网络用的都是 CPU——中央处理器。CPU 这东西什么都行，但什么都干得不算快。它擅长处理复杂的逻辑判断，可面对神经网络训练那种大量、简单、重复的矩阵运算，它就像让一个大学教授去数大米——聪明，但效率低。

吴恩达一直在琢磨：有没有一种工具，天生就适合做这种大量并行的简单运算？

于是他想到了 GPU——图形处理器。

GPU 本来是做游戏显卡用的。为了让游戏画面更流畅，它天生擅长做大量的并行计算——几万个核心同时开工，各自处理一小块数据。而神经网络训练，恰恰就需要这种大量、简单、重复的并行计算。

2008 年，吴恩达做了一个大胆的尝试。他用两块 NVIDIA GeForce GTX 280 显卡——当时市面上最强的 GPU——去训练一个具有 1 亿个参数的神经网络模型。

结果让人目瞪口呆：GPU 的并行计算速度是 CPU 的 70 倍。原本需要几个星期的计算，一天就干完了。

吴恩达后来回忆这个实验时，只说了一句话：“我意识到，神经网络不是算不动，是以前用的工具不对。”

这个发现的影响是深远的。GPU 本来是个“游戏配件”，可吴恩达的实验证明了一件事：它天生就是为神经网络而生的。从此，GPU 从游戏玩家的玩具，变成了 AI 研究者的标配。

2009 年，吴恩达用 GPU 搭建了斯坦福第一台用于深度学习的超

级计算机。2011 年，他加入谷歌，创立了 Google Brain 团队。可他很快发现，光有 GPU 还不够——还缺数据。

二、

再说数据。

2006 年，一位华裔女科学家刚刚从加州理工学院博士毕业，去了伊利诺伊大学做助理教授。她叫李飞飞。

李飞飞 1976 年生于北京，长在四川，16 岁随父母移民美国。她父亲是个工程师，母亲是个老师。刚到美国时，家境不好，她一边读书一边打工，在中餐馆端过盘子、在洗衣店叠过衣服。可她就是有一股不服输的劲儿——高中毕业时，她以全班第一的成绩被普林斯顿大学录取，拿了全额奖学金。

在加州理工读博士期间，李飞飞的研究方向是计算机视觉——让机器“看懂”图像。她做了几年，越做越觉得不对劲。

那时候，计算机视觉领域的所有人都在做同一件事：设计更好的算法。人人都觉得，只要算法够精巧，机器就能看懂世界。可李飞飞不这么想。她发现，问题根本不在算法，而在数据。

她在博士期间做了一个实验，试图让机器识别不同场景——街道、厨房、卧室、森林。可不管她怎么调算法，结果总是不理想。后来她意识到：训练算法的数据集太小了。那时候，计算机视觉领域最流行的数据集叫 PASCAL VOC，里面只有不到一万张图片，二十个类别。用这么少的数据训练，算法再好也学不会真实世界的复杂性。

李飞飞想：真实世界有成千上万种物体，每一种都有无数种外观、角度、光照变化。机器要真正学会“看”，需要的数据量，必须至少是现有数据集的几百倍。

这个想法听起来简单，做起来却难如登天。

2007 年，她回到母校普林斯顿大学，正式启动了 ImageNet 项目。目标是什么？22000 个类别，每个类别 1000 张图片——总计约 2000 万张。

刚开始，她雇了一批本科生，按每小时 10 美元的价格，手动搜索图片、手动标注。可很快她就发现——按这个速度，干完这个项目得十九年。

有人建议她用机器辅助标注。可李飞飞拒绝了。她说了一句很有哲学意味的话：“ImageNet 的使命，是把纯粹的人类感知嵌入每一张图片里。如果用机器来标注，那这个数据集从一开始就不纯了。”

办法只有一个——用人力，大量的人力。

李飞飞后来借助亚马逊的众包平台“Mechanical Turk”，发动了来自 167 个国家的 49000 名标注员，日以继夜地给图片打标签。她组织了一次又一次的标注任务，每一批图片都要经过严格的质检——标注不对的，打回去重来。

2009 年，ImageNet 正式发布。1500 万张图片，22000 个类别。这是人类历史上最大的图像数据集——没有之一。

可发布之后，没什么人理睬。在 2009 年的计算机视觉与模式识别大会上，李飞飞的团队只贴了一张学术海报。路过的人看了一眼，

点点头，走了。

李飞飞心里很清楚：数据建好了，可如果没人来用，再大的数据集也只是硬盘里的一堆文件。她需要一场比赛。

三、

2010 年，李飞飞和她的团队发起了一个比赛——ImageNet 大规模视觉识别挑战赛。规则很简单：用 ImageNet 提供的 150 万张训练图片，让算法学会识别一千种物体，然后在 10 万张测试图片上检验准确率。

第一年，参赛者的最好成绩是错误率 28%。第二年，最好成绩是 25%。每年只进步一点点，大家都觉得——这就是极限了。

2012 年，比赛又来了。李飞飞照例向全世界发出了邀请。可她不知道的是，这一年，有一只队伍正在准备一场“屠杀”。

这只队伍，来自多伦多大学。领队是深度学习三教父之一的杰弗里·辛顿，队员是辛顿的两个学生——亚历克斯·克里泽夫斯基和伊利亚·苏茨克韦尔。

克里泽夫斯基是个乌克兰裔的加拿大人，当时还是个研究生。他性格倔强，动手能力极强，在实验室里有个外号叫“代码狂人”——因为他可以连续熬夜几天几夜写代码，眼睛都不眨一下。

苏茨克韦尔也是乌克兰裔，比克里泽夫斯基小一岁，但天赋极其惊人。他后来回忆说，他们当时的设计灵感来自杨立昆的 LeNet——那个早在 1989 年就实现的手写数字识别网络。只不过，杨立昆的

LeNet 只有 5 层，而他们要做的，是一个 8 层的深度卷积神经网络。

他们把这个网络命名为 AlexNet——取自克里泽夫斯基的名字。

2012 年 9 月，比赛结果公布。

AlexNet 的 Top-5 错误率是 15.3%。第二名的错误率是多少？
26.2%。

足足领先了十个百分点。

这不是赢，这是碾压。

要知道，在此之前，每年 ImageNet 冠军的错误率改进都是以零点几个百分点来计算的。而 AlexNet 一次性把错误率砍掉了十个百分点——相当于直接把赛道上的所有人都甩开了十圈。

整个计算机视觉界都傻了。

更让人震撼的是：AlexNet 用的那些技术——ReLU 激活函数、Dropout 正则化、数据增强——没有一个是 2012 年才发明的。它们早就躺在论文里了，只是没人把它们组合在一起，也没人相信把它们组合在一起能有什么用。

那为什么 AlexNet 能赢？

因为辛顿团队做了三件事：

第一，用了 GPU。克里泽夫斯基用两块 GTX 580 显卡，把训练时间从几个月压缩到了几天。

第二，用足了数据。AlexNet 使用的是 ImageNet 的 150 万张图片——比之前任何数据集都大几十倍。

第三，算法调得好。他们把之前零散的技术（ReLU、Dropout、

数据增强）组合成了一个完整的系统，让 8 层网络能够稳定训练。

算法、数据、算力——三股力量，终于在 2012 年那个秋天会师了。

四、一场静悄悄的革命

AlexNet 的结果公布后，辛顿团队并没有高调庆祝。他们只是把论文挂到了 arXiv 上，然后继续埋头工作。

可在学术界，这场地震已经引发了海啸。

一个多月后，斯坦福大学计算机系的教授们聚在一起，讨论要不要在课程里加入深度学习。讨论的结果是：必须加。

几个月后，杨立昆在纽约大学收到了大量来自工业界的邮件——谷歌、Facebook、微软，都在问同一个问题：“你愿意来我们这边工作吗？”

一年后，辛顿带着两个学生，以 4400 万美元的价格把他们的公司卖给了谷歌。

而李飞飞呢？她看着 ImageNet 从无人问津变成了整个行业的“标配基准测试”，心里有说不出的高兴。多年后她回忆起这段经历时说：“ImageNet 的真正价值，不在于它是一个数据集，而在于它让所有人意识到——数据是人工智能的燃料。”

她这句话后来成了整个行业的共识。

五、

回头看这段历史，你会发现 2012 年的 AlexNet 并不是一个“天

才的灵光一闪”。它是三股力量在二十年里分别积累、最终汇合的结果：

算法：从 1943 年 M-P 模型，到 1986 年反向传播，到 1989 年 LeNet，再到 2012 年 AlexNet——每一步都有人踩坑，有人修正，有人坚持。

数据：从李飞飞 2007 年启动 ImageNet，到 2009 年发布，再到 2012 年比赛——一个科学家用五年的时间，为一个领域准备好了“燃料”

算力：从吴恩达 2008 年发现 GPU 的秘密，到 2012 年 AlexNet 用两块 GTX 580 跑通——一个关于“工具选择”的直觉，改变了整个行业的走向。

这三根柱子，没有一根是在 2012 年突然出现的。它们各自在暗处生长了多年，只是在这一年，恰好同时长到了足够粗壮的程度。

从此，深度学习不再是实验室里的玩具，而变成了一列真正的火车——它的速度越来越快，载重越来越大，轨道也越铺越远。

而推动这列火车的人，不仅有辛顿、杨立昆、本吉奥这些“算法大师”，还有李飞飞这样的“数据工匠”，以及吴恩达这样的“算力发现者”。

他们可能从不曾坐在同一张桌子上吃饭，但他们都相信同一件事：让机器学会“看”世界。

正是：

显卡原是游戏物，谁料竟成 AI 芯。

七十倍速震寰宇，计算从此换引擎。

千万图片人工标，四万九千一夜行。

算法数据算力合，2012 惊雷声。

欲知这 2012 年的一声惊雷，如何把深度学习从暗河推向洪流，
又如何让全世界突然发现——机器真的会“看”了，且听下回分解。

第七回

谷歌掷千金买火种 AlphaGo 一子定乾坤

话说 2012 年那个秋天，AlexNet 在 ImageNet 上一战封神的消息，像一阵飓风刮遍了全球计算机学界。那些曾经把神经网络视为“学术毒品”的教授们，一夜之间改了口——仿佛他们从来没有嘲笑过这个方向。那些曾经拒绝发表神经网络论文的期刊编辑部，一夜之间调转了方向——仿佛那二十年的冷眼从来没有发生过。

现实就是这样，成王败寇。你赢了，过往的一切都是“坚持”“忍耐”；你输了，过往的一切都是“不知变通”“冥顽不灵”。

而辛顿、杨立昆、本吉奥这三个人，等了二十多年，终于等到了从“固执”变成“坚持”的这一天。

最先闻到味道的，是谷歌。

一、

2012 年 12 月，AlexNet 发表仅仅两个月后，谷歌大脑团队的负责人杰夫·迪恩就拨通了辛顿的电话。迪恩开门见山地说：“我们想请你去山景城谈谈。不谈学术，只谈一件事——谷歌收购你和你学生刚刚成立的那家公司。”

那家公司叫什么？叫 DNNresearch——深度神经网络研究公司。这家公司成立的时间短得可笑：2012 年秋天，辛顿带着两个学生克

里泽夫斯基和苏茨克韦尔，在加拿大注册了这家公司。公司没有产品，没有商业模式，甚至没有一间像样的办公室。它唯一值钱的东西，就是这三个人脑子里的知识和算法。

可就是这家”皮包公司”，在 2013 年 3 月引发了一场竞购大战。

谷歌出价了。百度也出价了。还有另外几家硅谷巨头，都在暗中报价。价格从几百万美元一路飙升——辛顿后来回忆说，当竞标价格超过 2000 万美元时，他“不得不暂停拍卖，因为开始觉得荒谬”。

最终，谷歌以约 4400 万美元的价格，拿下了 DNNresearch。辛顿本人加入了谷歌，克里泽夫斯基和伊利亚·苏茨克韦尔也一并入职。

这场收购，在硅谷的历史上根本排不上号——4400 万美元，连谷歌收购 YouTube 花的那 16 亿美元的零头都不到。可它释放了一个信号：全球最大的科技公司，开始用真金白银押注深度学习。

这信号一出，整个行业都坐不住了。

紧随其后的是 Facebook。

马克·扎克伯格亲自飞到纽约大学，请杨立昆共进晚餐。席间，扎克伯格问了一个直截了当的问题：“如果 Facebook 要做人工智能研究，第一把交椅应该给谁坐？”

杨立昆想了想，报出了几个名字。扎克伯格听完，放下刀叉，看着杨立昆的眼睛说了一句：“那，你来坐。”

2013 年底，杨立昆离开纽约大学，加入 Facebook，创立了 FAIR——Facebook 人工智能研究院。他的任务只有一个：把深度学习的火种，带进全世界最大的社交网络。

同年，本吉奥虽然没有加入任何一家巨头公司，但他创立的 MILA——蒙特利尔学习算法研究所——获得了加拿大政府和工业界的巨额资助，成为全球最大的深度学习学术中心之一。

至此，深度学习三教父——辛顿进了谷歌，杨立昆进了 Facebook，本吉奥坐镇学术界。三足鼎立的格局，就此形成。

可学术界和工业界的热闹，还仅限于圈内人。深度学习真正走向大众，要靠一个“出圈”的事件。

这个事件，发生在 2016 年春天。

二、

2016 年 3 月 9 日，韩国首尔四季酒店。一场围棋比赛正在进行。

执黑的一方，是李世石——过去十年全世界最顶尖的围棋棋手之一，十八次世界冠军得主。执白的一方，是一台机器——来自谷歌 DeepMind 公司的围棋程序“AlphaGo”。

围棋这个东西，跟国际象棋不一样。国际象棋每一步平均只有 35 种走法，而围棋平均有 250 种。一局棋下来，可能的走法数量远远超过了宇宙中原子的总数。传统的人工智能方法，比如穷举搜索、专家规则——在围棋面前统统失效。计算机攻克国际象棋早在 1997 年就做到了，可围棋一直被认为是“人类智慧的最后堡垒”。

为什么？因为围棋需要的不只是计算，还有“直觉”。顶级棋手下棋，很多时候靠的是说不清道不明的“棋感”——一种基于千万盘对局积累出来的、无法用规则描述的判断力。计算机可以算得很快，

但它“没有感觉”。

然而 AlphaGo 跟以往所有的围棋程序都不一样。它用了深度神经网络和强化学习——先让它看人类高手下过的三千万盘棋，学会“像人一样下”；再让它自己跟自己下，不断迭代、不断进化。到对阵李世石的时候，AlphaGo 已经自己跟自己下过了几千万盘——它积累的经验，相当于一个人类棋手下几千年的量。

第一盘，AlphaGo 赢了。第二盘，又赢了。第三盘，还是赢了。三盘战罢，李世石的脸上一片茫然。第四盘，他奋力扳回一局。可最终，比分定格在 4:1。

人类围棋世界冠军，败给了一台机器。

这一消息，当天就登上了全世界所有主流媒体的头版头条。观众人数达到了 2.8 亿。人们猛然意识到——那个曾经只会“看图识字”的深度学习，如今已经能在世界上最复杂的棋盘上，战胜最顶尖的人类选手。

更可怕的是，AlphaGo 在第二局下出了一步人类棋手从未走过的“神之一手”——第 37 手，它在棋盘边缘落了一子。所有围棋解说员都愣住了——按照人类几千年的棋理，这一步是一手纯纯的俗手。可后来复盘证明，这一步恰恰是锁定胜局的关键。

人类几千年的经验，被一台机器用一步棋重新定义了。

三、

回过头来看，AlphaGo 的意义，远远超出了围棋本身。

AlexNet 证明了机器能“看”，AlphaGo 证明了机器能“想”。前者让学术界震动，后者让全世界震动。

2.8 亿观众，不分国界、不分年龄、不分行业——他们在同一时间，看到了同一个画面：人类最顶尖的棋手，在一个被公认为“不可能被机器攻克”的领域，被一台机器干净利落地击败。

那是一种说不清道不明的震撼。你看着屏幕上那个不断落子的白色光标，你知道那不是人在下棋，但你又总觉得“它好像在思考”——这感觉让人脊背发凉，又让人心潮澎湃。

AlphaGo 之后，所有的围棋选手都开始学习 AI 的下法。人类的围棋技艺，因为机器的介入而提升到了新的高度。可 AlphaGo 真正的贡献，是向全世界释放了一个强烈的信号：深度学习不是实验室里的玩具，它能解决真实世界中的人类难题。

四、

这个信号落地生根的速度，比所有人预想的都要快。

2011 年，苹果在 iPhone 上推出了 Siri——第一个大规模商用的语音助手。人们对着手机说话，手机能听懂。这背后是深度学习在语音识别上的突破。

2014 年，Facebook 的 DeepFace 在面部识别准确率上超越了人类水平——你上传一张照片，它能认出来谁是谁。

2015 年，微软的 ResNet 在 ImageNet 上把错误率降到了 3.57%——人类水平大约是 5%，这是计算机第一次比人“看得更准”。

2016 年，谷歌翻译全面升级为神经机器翻译系统——一夜之间，翻译质量提升了“超过十年”。

这一年，谷歌的塞巴斯蒂安·特龙开始用深度学习训练自动驾驶汽车。年底，Waymo 从谷歌独立出来，成为一家独立的自动驾驶公司。

深度学习像一列突然加速的火车，呼啸着冲进了人类生活的每一个角落。语音识别、图像识别、自动驾驶、医疗诊断、机器翻译、推荐系统——几乎你能想到的每一个领域，都在被深度学习重新塑造。

五、

回顾这一波浪潮，你会发现一个有趣的现象：深度学习在 2012 年到 2016 年这四年间的突破，其核心原理——卷积神经网络——其实早在 1989 年就被杨立昆写在了论文里。

那些改变世界的技术——ReLU、Dropout、GPU 并行训练、大规模数据集——没有一个是 2012 年之后发明的。它们只是在角落里等了二十年，等到了一个叫“AlexNet”的组合者，把所有的零件拼在了一起。

这告诉我们一个道理：有时候，真正的突破不是发明了全新的东西，而是把已有的零件组装成了一个从未有过的整体。

辛顿的坚持、杨立昆的工程、本吉奥的理论、吴恩达的 GPU 实验、李飞飞的 ImageNet、克里泽夫斯基那一夜通宵写代码把 AlexNet 跑出来的那份狠劲——这所有的一切，在 2012 年秋天汇聚成了一道

光。然后这道光照进了谷歌、照进了 Facebook、照进了全世界的实验室、最后照进了 2.8 亿观众的手机屏幕里。

从 1943 年的 M-P 模型，到 2016 年的 AlphaGo，这条路走了七十三年。在这七十三年里，神经网络被人捧上过天，也被人踩进过泥；有过两次漫长的寒冬，也有过短暂的虚假繁荣；有人在嘲笑中放弃，也有人在孤独中坚守。

那个曾经在 1970 年代被明斯基一本书打入冷宫的“穷亲戚”，如今成了全世界的座上宾。

可故事还没完。2017 年，就在 AlphaGo 战胜李世石仅仅一年之后，一篇只有八位作者、标题平平无奇的论文，被悄悄投递到了一个学术会议上。这篇论文的标题叫《Attention Is All You Need》。

没有人知道，这篇论文即将开启人工智能的下一个时代。

正是：

谷歌千金买火种，三足鼎立局面成。

AlphaGo 一子落，围棋天堑变通途。

语音图像翻译识，深度学习全面兴。

七十三年沉浮事，只待 Transformer 开新途。

欲知这篇《Attention Is All You Need》究竟写了什么，它又是如何用一个叫“自注意力”的机制，彻底改写了整个人工智能科学的游戏规则，且听下回分解。

第八回

一张注意力之网 万语千言皆相通

话说 2016 年的谷歌山景城总部，深度学习的热浪正一浪高过一浪。AlphaGo 刚刚击败了李世石，全世界都在为神经网络的威力而惊叹。可在谷歌内部的某个角落，一个德国年轻人却对着屏幕皱起了眉头。

他在想一个问题：为什么机器理解一句话，非得一个字一个字地来？

一、

这个年轻人叫雅各布·乌什科雷特。他出身颇为不凡——父亲汉斯·乌什科雷特是著名的计算语言学家，上世纪 60 年代因抗议苏联入侵捷克斯洛伐克而被东德监禁，获释后逃往西德，后来成了自然语言处理领域的权威。雅各布继承了父亲的头脑，却没有走父亲的老路。2012 年，他做了一个关键决定——放弃攻读博士学位，加入谷歌的一个特别团队。

这个团队负责开发一个能在搜索页面直接回答用户问题的系统。雅各布每天面对的都是同一个难题：让机器理解人类的语言。

那时候，自然语言处理领域的主流架构是循环神经网络（RNN）和它的改进版长短期记忆网络（LSTM）。RNN 的工作方式很直观：

从左到右逐个处理单词，每一步都把当前单词和之前的“记忆”结合起来。这个设计看起来很自然——毕竟人类也是从左到右阅读句子的。

可它有两个致命缺陷。

第一个缺陷：无法并行计算。要计算第 10 个词的隐状态，必须先算第 9 个；要算第 9 个，必须先算第 8 个。这个链条像多米诺骨牌一样，推倒第一张，后面的才能依次倒下。在 GPU 时代，这简直是灾难——GPU 有几千个核心，可 RNN 偏偏逼着你一个一个地算。

第二个缺陷：长距离依赖的信息衰减。假设你要翻译这个句子：“那只猫，我们去年夏天在花园里找到的，非常亲人。”主语“猫”和谓语“非常亲人”之间隔了十几个词。RNN 需要把“猫”的信息一步一步地传过去，每传一步就衰减一点。传到最后一个词的时候，前面的信息早就不剩多少了。

LSTM 用“门控”机制缓解了这个问题，但没有根本解决。本吉奥早在 1994 年就证明了：RNN 在学习长程依赖时，梯度会指数级衰减。

雅各布越想越觉得不对劲：人类读一个句子，难道是一个字一个字地读完了才理解的吗？不，人类是一眼看过去，瞬间就抓住了整句话的意思。

那为什么机器非得按顺序来呢？

二、

2016 年的某个午后，雅各布在谷歌山景城的会议室里，提出了

一个大胆的想法。

这个想法叫做“自注意力机制”。通俗地说：让句子里的每一个词，都能直接“看到”句子里的所有其他词，然后自己判断——哪些词跟我关系大，哪些关系小。关系大的，我就多听它的；关系小的，我就少听它的。

打个比方：你在一个房间里，同时有十个人在说话。你的耳朵不会一个一个地听——你是一下子听到所有人的声音，然后自动把注意力集中到那个说话最重要的人身上。自注意力机制，就是这个“自动聚焦”的能力。

这个想法一旦冒出来，雅各布就再也放不下了。他开始在谷歌内部找人合作。

第一个加入的，是阿什什·瓦斯瓦尼——印度裔，在中东长大，2014 年在南加州大学拿到博士学位，2016 年加入 Google Brain 团队做研究科学家。瓦斯瓦尼是机器翻译的专家，他一听雅各布的想法，眼睛就亮了。

第二个加入的，是妮琪·帕玛尔——来自印度西部浦那，也在南加州大学读过书，是 Google Brain 团队里少有的女性工程师。

三个人凑在一起，开始把这个想法变成现实可以运行的代码。

三、

在继续讲故事之前，先停下来解释清楚一个关键问题——为什么“自注意力”这么厉害？

这要从三种架构的对比说起。

RNN：排队发言。想象一个会议室，十个人围坐一圈，但规则是：只有一个人能说话，而且必须按顺序来。第一个人说完，第二个人才能接上；第二个人说完，第三个人才能接上。而且每个人说话的时候，只能听到前一个人的声音，听不到后面的人。这就是 RNN——从左到右，一个词一个词地处理，每个词只能“看到”前面的词。

CNN：只听身边几个人。还是那个会议室，但规则变了：每个人只能听到坐在自己左右两边的两三个人的声音。离得远的，就听不见了。这就是 CNN——它擅长处理局部信息，比如图像里相邻的像素，但处理长距离依赖时就会“听不见远处的人说话”。

Attention：所有人同时看全场。规则又变了：每个人都能同时听到所有其他人的声音，而且可以自己决定——谁的声音对我最重要，我就多听谁的；谁的声音跟我没关系，我就少听谁的。这就是注意力机制——它不关心距离，不关心顺序，每一个词都能直接看到句子里的所有其他词，然后自己判断该关注谁。

Transformer：每个人决定自己该关注谁。Transformer 把“注意力”这件事做到了极致。它不只是“能看全场”，它还设计了一种精巧的方式——通过“多头注意力”，让模型能同时从多个不同的角度去理解同一个句子。就像一个团队里，有人关注语法结构，有人关注语义关联，有人关注上下文逻辑——每个人从不同的角度“看”这句话，最后把所有人的理解合并在一起，形成一个更完整的认识。

而且，Transformer 有一个比 RNN 和 CNN 都厉害的地方——它

非常适合规模化。

为什么？因为 RNN 必须一个一个地算，不能并行；CNN 能并行但“视野”毕竟有限；而 Transformer 的注意力机制——每一个词同时看所有词——天然就是并行的。GPU 可以同时计算所有词之间的关联，不需要排队。

这意味着什么？意味着你只要把模型做大、把数据做大、把 GPU 的数量做大，Transformer 的威力就会越来越大。它像一个可以无限扩容的工厂——你给它加机器、加原料，它就能产出更多的产品。

这个特性，是后来 GPT、BERT、ViT 等模型能够爆发的最根本原因。Transformer 不只是“聪明”，它更是“可发展的聪明”。

四、

回到故事。光靠三个人还不够。这个项目需要更多的大脑、更多的手。

2017 年初，又有几个人陆续加入了这个团队。

诺姆·沙泽尔——谷歌的“老炮儿”，在公司已经干了将近二十年。他开发过谷歌搜索的拼写纠正、广告系统、垃圾邮件检测——凡是谷歌的核心产品，几乎都有他的影子。他是最后一位加入这个团队的，却起到了最关键的作用。他根据团队已有的想法，从头重写了整个项目的代码。团队成员后来说，沙泽尔施了“魔法”——他不仅大幅提升了系统性能，还提出了多头注意力机制等关键创新，让这个架构从理论走向了实用。

利昂·琼斯——英国人，曾在 YouTube 工作，自学机器学习后于 2015 年加入谷歌研究院。他后来做了一件让全世界记住他的事，我们一会儿再讲。

卢卡什·凯泽——TensorFlow 的核心作者之一，Google Brain 的资深研究员。

伊利亚·波洛苏金——乌克兰人，谷歌深度学习小组的项目主管，也是 TensorFlow 开源项目的主要代码贡献者。他是八人中最早离开谷歌的，2017 年就与其他人共同创立了区块链公司 NEAR Protocol。

还有一位最年轻的——艾丹·戈麦斯。当时他还是多伦多大学的本科生，主动联系了深度学习三教父之一的辛顿，通过实习进入了 Google Brain。一个本科生，在一群资深研究员中间，居然也做出了不可或缺贡献——他帮助建立了名为 Tensor2Tensor 的软件基础设施，让 Transformer 能在成千上万的 GPU 之间分配计算任务。

八个人，八个背景，八种专长——就这样凑齐了。

五、

2017 年春天，这八个人关在谷歌的办公室里，开始了为期六十天的冲刺。

他们的目标很朴素：改进谷歌的机器翻译。谷歌翻译是谷歌最重要的产品之一，每天处理数十亿字的翻译请求。当时的翻译系统基于 RNN 和 LSTM，速度慢、准确率也不够理想。这八个人相信，用“自注意力”取代“循环”，能让翻译又快又好。

他们日夜兼程。瓦斯瓦尼和波洛苏金设计和实现了第一个Transformer模型。沙泽尔提出了缩放点积注意力、多头注意力和无参数位置表示。凯泽和瓦斯瓦尼经常为自注意力的细节争得面红耳赤。

有一天，沙泽尔路过他们争论的房间，听到他们的讨论后觉得很有前途，便主动加入了进来。这一加入，彻底改变了项目的走向。

论文快写完的时候，八个人面临一个棘手的问题：作者顺序怎么排？在学术圈，作者排序是个极其敏感的事——第一作者意味着最大的贡献，排最后的基本等于“打杂的”。可这八个人，每个人都有自己的独特贡献，谁也压不过谁。

他们最终做了一个“离经叛道”的决定：在每位作者名字后面标注星号，并在脚注里明确写道——“各位作者的贡献同等重要，名次排列完全随机”。

这在当时的学术界，几乎闻所未闻。

六、

论文写完了，可标题还没定。

八个人坐在会议室里，七嘴八舌地讨论。有人提议叫这个，有人提议叫那个，谁也说服不了谁。

这时候，英国人利昂·琼斯开口了。他想起了一首披头士乐队的经典老歌——《All You Need Is Love》（你只需要爱）。

“Attention Is All You Need.” 琼斯脱口而出。

他后来说，他想出这个主意只花了五秒钟。“我没想到他们真的

会用这个名字。”

可大家一听，都觉得妙极了——“你只需要注意力”。既点明了论文的核心思想，又有披头士的文艺范儿。

2017 年 6 月 12 日，一个普通的周一，这篇只有 11 页的论文被上传到了 arXiv 预印本平台。标题赫然写着：《Attention Is All You Need》。

这篇论文的口气很大。RNN 和 LSTM 统治自然语言处理领域已经超过二十年，可这篇论文说：你们都不需要了，只需要注意力就够了。

更“狂妄”的是——他们是对的。

七、

五个月后，这篇论文被 NIPS2017 学术会议接收。可有趣的是，这篇后来改变世界的论文，在当年并没有拿到口头报告的机会——只被安排在了晚间海报展示环节。那些评审委员们，谁也没看出这篇论文将来会引发何等翻天覆地的变化。

可在之后的几年里，它的引用量如同坐了火箭——两年后突破 1 万次，五年后突破 5 万次，如今已超过 18 万次。它成了人工智能领域被引用最多的论文之一。

更重要的是，它催生了一整个时代。

2018 年，BERT 和 GPT-1 横空出世，全部基于 Transformer 架构。2019 年，GPT-2 发布。2020 年，GPT-3 把 Transformer 扩展到了 1750

亿参数。2022 年底，ChatGPT 引爆全球——它的核心技术，依然是 Transformer。

这篇论文的八位作者，如今已全部离开了谷歌。有人创办了估值数十亿美元的 AI 独角兽，有人被谷歌以 27 亿美元“回购”，有人投身加密货币领域创造了百亿市值。聚是一团火，散是满天星。

而 Transformer 这个架构——它的名字原本只是“变形金刚”的意思——如今已经成了整个现代人工智能的代名词。

正是：

循环串行二十载，长程依赖总难裁。

八子聚首谷歌内，自注意力破局来。

披头士歌化标题，一纸惊世天下开。

莫道当年海报展，且看今朝满乾坤。

欲知这 Transformer 如何催生了 GPT 与 BERT 的“双雄并立”，大模型时代又是如何从一篇被安排在晚间海报展示的论文中崛起的，且听下回分解。

第九回

GPT、BERT 双雄并立 预训练范式一统江湖

话说 2017 年 6 月，那篇《Attention Is All You Need》刚刚被上传到 arXiv 的时候，并没有多少人意识到它意味着什么。在当年的 NIPS 会议上，它被安排在了晚间海报展示环节——一个不起眼的角落，几张展板，几个路过的学者停下来看了几眼，点点头，走了。

可种子已经埋下去了。而且，发芽的速度比所有人预想的都快。

仅仅一年之后，两篇改写历史的论文几乎同时问世。一篇来自一家彼时名不见经传的非营利机构 OpenAI，另一篇来自当时全球最大的科技公司 Google。它们一个叫 GPT，一个叫 BERT。从此，大模型时代的大幕，被这两只手同时拉开。

一、

先说 GPT。

2018 年 6 月，旧金山。一家成立不到三年的小公司 OpenAI 发表了一篇论文，题为《通过生成式预训练提高语言理解能力》。论文的第一作者，是一个叫亚历克·拉德福德的年轻人。

拉德福德是个低调的人。他不怎么在社交媒体上发言，也不怎么参加学术会议。他最喜欢的事是坐在办公室里写代码，一写就是一整天。可他写的代码，后来改变了整个世界。

这篇论文做了件什么事呢？简单来说，它提出了一个叫做“预训练+微调”的新范式。

在 GPT-1 出现之前，自然语言处理领域有个老大难的问题：每个任务都需要从头训练一个模型。你想做机器翻译？好，先找几百万句平行语料，标注好，从头训练一个翻译模型。你想做情感分析？好，再找几万条带情感标签的评论，从头训练一个情感分析模型。每个任务都是独立的，每个模型都是孤岛。你今天在翻译模型上积累的知识，明天做情感分析时一点都用不上。

这就好比什么？好比你想开一家餐馆，结果发现每做一道菜都得从种地开始——种小麦、磨面粉、生火、和面。你辛辛苦苦种出来的麦子，做完了这道菜就扔了，下一道菜还得重新种。

GPT-1 的想法恰恰相反：与其为每个任务从头开始，不如先让模型在一个大规模的无标签文本上“预习”一遍——学会通用的语言知识——然后再针对具体任务做少量的“复习”。

这个“预习”的过程，叫做预训练。GPT-1 用的预训练数据是 BookCorpus——一个包含 7000 多本未出版小说的数据集。为什么选小说？因为小说里有长句子、有上下文、有连贯的叙事——这些正好是训练语言模型理解长距离依赖所需要的东西。

在架构上，GPT-1 直接挪用了 Transformer 的解码器部分(Decoder Only)，堆叠了 12 层，每层 12 个注意力头，总参数量 1.17 亿。它只用了 Transformer 的“一半”——那个负责生成文本的解码器——从左到右、一个词一个词地往下预测。

预训练完成之后，GPT-1 再针对不同的下游任务——问答、分类、推理——做少量的微调。微调的时候，只需要在预训练模型的最后一层换上一个任务特定的“输出头”，然后用少量标注数据稍微调整一下参数就行了。

效果怎么样？GPT-1 在 12 项自然语言理解任务中的 9 项上，取得了当时的最优成绩。

这个成绩本身不算惊天动地——毕竟 1.17 亿参数在今天看来小得可怜。可它证明了一件事：“预训练+微调”这条路，走得通。

这条路一旦走通，后面的故事就不再是“能不能走”，而是“能走多远”了。

二、

然而，GPT-1 并非完美无缺。它有一个先天的问题：单向性。

GPT-1 用的是 Transformer 的解码器，只能从左到右地“看”文本——预测下一个词的时候，它只能看到前面的词，看不到后面的词。这在做文本生成的时候没问题——你写文章当然是一个字一个字地往后写。可在做语言理解的时候，这个限制就麻烦了。

举个例子。给你一个句子：“小明____苹果，因为口渴了。”让你填空。一个真正“理解”了这个句子的模型，应该同时看到前后的信息——前面有“小明”，后面有“因为口渴了”——才能判断出空格最合适的是“吃了”还是“买了”还是“看着”。可 GPT-1 只能从左到右看，它看到空格的时候，还不知道后面有“因为口渴了”

这句话。

这就好比一个人蒙着一只眼睛看世界——能看到，但看不全。

Google Brain 团队的几个人注意到了这个问题。

2018 年 10 月，就在 GPT-1 发表四个月后，谷歌的研究员雅各布·德夫林、张明伟等人发表了一篇论文，标题叫《BERT：语言理解的深度双向 Transformer 预训练》。

BERT 的全称是 Bidirectional Encoder Representations from Transformers——来自 Transformer 的双向编码器表征。

它的核心思想，用一句话就能说清：双向。

GPT 用的是 Transformer 的解码器，从左到右单向；BERT 用的是 Transformer 的编码器（Encoder Only），左右都能看，双向。为了让模型做到真正的双向，BERT 设计了一个巧妙的预训练任务，叫做“掩码语言模型”。具体做法是：在输入句子中随机“盖住”15%的词，让模型根据上下文——左右两边都看——来猜这些被盖住的词是什么。

打个比方。GPT 的预训练像是让你接话——给你前半句话，让你猜后半句。BERT 的预训练像是让你完形填空——给你一个挖了空的句子，让你根据上下文填上最合适的词。

接话和完形填空，哪个更能锻炼语言理解能力？答案不言自明。

BERT 的训练数据也比 GPT-1 大得多——它用了整个英文维基百科，25 亿词，和一个图书语料库，8 亿词。模型参数量分为两个版本：BERT-Base，1.1 亿参数，12 层；BERT-Large，3.4 亿参数，24 层。

效果呢？BERT 在 11 项自然语言处理任务上刷新了历史纪录。
在机器阅读理解测试 SQuAD 上，BERT 的表现首次超越了人类水平。

整个学术界被震动了。BERT 发表仅仅四个月后，就被引用了上千次。它成了 2018 年整个 AI 领域最炙手可热的研究成果。

三、

GPT 和 BERT，一个在 2018 年 6 月，一个在 2018 年 10 月。一个用单向解码器，一个用双向编码器。一个擅长“生成”，一个擅长“理解”。一个来自旧金山的小公司 OpenAI，一个来自硅谷的巨头 Google。

这两篇论文，像是约好了一般，共同开启了一个全新的时代。

在此之前，自然语言处理领域的主流做法是“为每个任务设计专门的模型”——做情感分析的用一种架构，做问答的用另一种架构，做翻译的又用另一种架构。每个模型都是孤岛，每个任务都要从头开始。

在此之后，一切都变了。“预训练+微调”成了整个 NLP 领域的新范式。你先在一个大模型上做预训练，然后针对任何下游任务做微调——问答、分类、推理、翻译，统统可以用同一个模型搞定。

这就像什么？就像你以前每做一道菜都要从种地开始——种小麦、磨面粉、生火、和面——现在有人告诉你：面粉我已经给你磨好了，你只需要根据不同的菜式加点不同的调料就行了。

GPT 和 BERT，就是那两袋磨好的面粉。一袋是“通用面粉”，

一袋是“低筋面粉”——用途略有不同，但本质都是把“从零开始”变成了“站在巨人的肩膀上”。

可“预训练+微调”这个范式，真的是 GPT 和 BERT 发明的吗？

也不全是。在 2018 年之前，已经有一些先驱者在做类似的事情了。2018 年初，艾伦人工智能研究所发布了 ELMo 模型，首次提出了“上下文词向量”的概念。几乎同时，fast.ai 的霍华德和鲁德尔发布了 ULMFiT，首次证明了“预训练语言模型+微调”在文本分类上的有效性。

可以说，ELMo 和 ULMFiT 是铺路石，GPT 和 BERT 是铺完路后开过来的第一辆车。前者证明了这条路能走，后者证明了这条路能走多远。

区别在于：ELMo 和 ULMFiT 用的还是老架构——LSTM 和 RNN，而 GPT 和 BERT 用的是 Transformer。Transformer 的并行计算能力和长距离依赖建模能力，让“预训练+微调”这个想法从“理论上可行”变成了“实践中碾压一切”。

正如一位评论者所说：“2018 年的 GPT 和 BERT 论文并没有发明预训练，它们继承了预训练的配方——然后用 Transformer 把它做成了满汉全席。”

四、

2018 年那场“双雄并立”的格局，并没有持续太久。

GPT 和 BERT 虽然同年诞生，但走的路完全不同。BERT 走的是

“深度双向理解”路线——它的目标是让机器读懂人类语言。GPT 走的是“生成式预训练”路线——它的目标是让机器写出人类语言。

在当时，学术界普遍认为 BERT 的路线更“正确”——毕竟“理解”是“生成”的前提，你都不理解，怎么能生成得好呢？所以在 2018 到 2019 年间，BERT 的引用量远超 GPT-1，谷歌的路线似乎占了上风。

可 OpenAI 没有跟风。他们做了一个在当时看来近乎疯狂的决定：继续沿着 GPT 的路线走下去，把模型越做越大。

这个决定的背后，站着一个人——伊利亚·苏茨克韦尔，OpenAI 的联合创始人兼首席科学家。

伊利亚是辛顿的学生，就是那个和克里泽夫斯基一起写出 AlexNet 的乌克兰裔年轻人。2012 年 AlexNet 一鸣惊人之后，伊利亚去了谷歌，后来又离开谷歌，和几个朋友一起创办了 OpenAI。

伊利亚信奉一个在当时看起来近乎偏执的理念：“扩大模型规模，能力就会涌现。”

什么叫“涌现”？就是当模型的参数规模、训练数据量或训练步数达到某个临界阈值后，模型会突然展现出在小模型中完全不存在或极其微弱的能力——比如逻辑推理、少样本学习、复杂指令遵循、代码生成。这种能力不是慢慢变好的，而是跨过某个门槛之后突然冒出来的。

在当时，大家都觉得他疯了。因为这太反直觉了——凭什么把模型做大，它就会突然变聪明？

可伊利亚执拗地相信这件事。他在 OpenAI 内部反复强调：“规模就是一切。我们不需要发明更聪明的算法，我们只需要把已有的算法做得足够大。”

2019 年 2 月，他带着 OpenAI 交出了第一份答卷——GPT-2。

五、

GPT-2 的参数量是 15 亿——比 GPT-1 的 1.17 亿大了十倍不止。训练数据是 800 万个网页、总共 40GB 的文本。

GPT-2 最惊人的地方在于：它没有经过任何微调，就能完成多种任务。你给它一段英文，它能翻译成法文；你给它一个问题，它能直接回答；你给它一个开头，它能续写出一篇连贯的文章。有研究显示，GPT-2 生成的文本与《纽约时报》的真实文章有 83% 的相似度——人几乎分不清哪个是机器写的，哪个是人写的。

可恰恰是这种“太像人”的能力，引发了争议。

OpenAI 宣布：不公开 GPT-2 的完整模型权重。理由是：担心这个模型被用来批量生成假新闻、欺诈内容。

这个决定在学术界炸了锅。有人嘲讽 OpenAI 应该改名叫“CloseAI”。杨立昆和另一位著名学者 Kyunghyun Cho 公开表示不满。支持者说这是在负责任地做事，反对者说这是在开倒车。

这场争论持续了将近一年。直到 2019 年 11 月，OpenAI 才分阶段地公开了 GPT-2 的完整代码。

可不管争议多大，有一件事是确定的：GPT-2 向全世界展示了“规

模”的威力。一个模型，不做任何任务特定的训练，就能干这么多事——这在以前是想都不敢想的。

六、

既然 15 亿参数的模型已经这么厉害了，那 1750 亿的呢？

2020 年 6 月，OpenAI 给出了答案——GPT-3。

1750 亿参数。比 GPT-2 大了一百多倍。训练数据达到了 45TB。训练成本估算高达 1200 万美元。模型权重文件大小超过 350GB。

GPT-3 的论文标题起得很有意思——《语言模型是小样本学习者》。它想说的是：你不需要再为每个任务做微调了，只需要在提示里给几个例子，GPT-3 就能自己学会怎么做。

这叫“上下文学习”。

翻译？给几个英法对照的例子，GPT-3 就会了。算术？给几个“ $2+3=5$ ”的例子，GPT-3 就会了。代码生成？给几个 Python 函数的例子，GPT-3 就会了。

它没有专门学过这些任务。它只是在“预测下一个词”的过程中，自己悟出来了。

更让人震惊的是涌现能力。GPT-2 做不到的事情——比如多步推理、算术、常识判断——GPT-3 突然就能做到了。不是慢慢地变好，而是跨过某个阈值之后突然冒出来的。

这就像什么？就像你养一个孩子，他长到一米六九的时候什么都不会，突然长到一米七的时候就会微积分了。

科学家们给这种现象起了个名字，叫“涌现”。没人能完全解释为什么会出现这种现象。大家只知道一件事：规模大到一定程度，奇迹就会发生。

伊利亚·苏茨克韦尔赌赢了。

七、

从 2018 到 2020，不过短短三年。

GPT-1，1.17 亿参数，证明了“预训练+微调”可行。

BERT，3.4 亿参数，证明了“双向理解”更强大。

GPT-2，15 亿参数，证明了“规模”能带来“零样本”能力。

GPT-3，1750 亿参数，证明了“规模再大一百倍”能带来“涌现能力”。

三年时间，参数规模从 1 亿涨到了 1750 亿——涨了一千五百倍。训练数据从几本书涨到了 45TB 的互联网——涨了不知道多少倍。模型能力从“能做填空题”涨到了“能写文章、能翻译、能编程、能推理”——涨得让人难以理解。

可 GPT-3 还缺一样东西。

它很强，但它藏在论文里、藏在 API 里，普通人见不着、摸不到。你得会写代码、会调参数、懂得什么叫“提示词工程”，才能跟它说上话。它就像一座藏在深山里的宝藏——大家都知道它在那儿，可没几个人真正见过它。

要把这座宝藏搬到每个人的口袋里，还需要最后一把火。

这把火，会在两年后的一个冬天点燃。

正是：

GPT 初生惊四座，BERT 双向震乾坤。

预训练成新范式，微调一统 NLP 门。

GPT-2 显零样本力，十五亿数初现神。

GPT-3 千亿惊天下，涌现能力始现身。

只待冬日一把火，ChatGPT 照世人。

欲知这 GPT-3 如何从藏在深山的宝藏变成人人都能用的 ChatGPT，它又是如何在两个月内席卷全球、让十亿人第一次真正感受到人工智能的威力，且听下回分解。

第十回

ChatGPT 一朝惊天下 AI 热潮两月卷五洲

话说上一回讲到，GPT-3 在 2020 年夏天横空出世，1750 亿参数震惊了整个 AI 界。可它有两个问题：一是藏在 API 背后，普通人用不了；二是虽然强大，却经常“口无遮拦”——你问它“怎么造炸弹”，它能给你列一份详细的材料清单；你问它“为什么太阳从东边升起”，它正经回答；你问它“太阳明天会不会从西边升起”，它也正经回答。

一个模型不怕“不会答”，怕的是连“不该答”的都答得头头是道。

这就好比一个有超强记忆但没有常识的“神童”——他能背下整本百科全书，却分不清什么时候该说什么话。

OpenAI 的人开始琢磨一个根本性的问题：怎么让模型既能回答问题，又能遵守规矩？

一、

答案来自一个叫做“基于人类反馈的强化学习”的技术——简称 RLHF。

用通俗易懂的话来说，RLHF 的核心思想就是四个字：教它做人。

怎么教呢？分三步走。

第一步：拿一堆问题，让模型给出多个不同的回答。然后找一

群标注员——成千上万的人——坐在电脑前，给这些回答打分：“这个好，那个差。”、“这个礼貌，那个粗鲁。”、“这个准确，那个胡说八道。”这些打分数据，就成了模型的“道德教材”。

第二步：根据这些人类打分，训练一个奖励模型。这个奖励模型就像个老师——它学会了人类喜欢什么样的回答、不喜欢什么样的回答。

第三步：用这个奖励模型来训练主模型。主模型每回答一个问题，奖励模型就在旁边打分——答得好，给高分；答得差，扣分。主模型的目标只有一个：获取最高的奖励分。

这个过程就像一个学生被一位老师反复训练——老师从不告诉学生“为什么”这个答案好，只是不断地给出对错的反馈。学生在一次次试错中，自己学会了判断什么该说、什么不该说。

说起来简单，做起来却极其复杂。一个 1750 亿参数的模型，每一次微调都是一场算力的大震荡。OpenAI 花了将近两年的时间，几百万美元的成本，几十万条人工标注数据，才把这项工作做到位。

可这一切的付出，在 2022 年 11 月 30 日那天，被证明是值得的。

二、

2022 年 11 月 30 日，一个普通的周三。

OpenAI 在官网上低调地发布了一个新产品的链接，名为“ChatGPT”。没有任何发布会，没有任何媒体预热。它就像一个在深夜里悄悄点亮的小窗口。

这天下午，还在谷歌工作的利昂·琼斯——就是那个给 Transformer 论文起名的英国人——在社交媒体上随手发了一句话，说 ChatGPT “可能是有史以来最好的文本生成用户界面”。他当时根本不会想到，这句话后来被引用了几万次。

ChatGPT 不但是一个模型，更是一个“对话界面”。此前，跟 GPT-3 交流需要会写代码、懂 API、会调参数。可 ChatGPT 只有一个文本框——你在里面打字，它就在下面回复。就这么简单。

一个程序员在新泽西的家中打开了这个页面。他随便打了一行字：“写一首关于冬天的诗。” ChatGPT 不到两秒钟就写出了一首押韵工整的诗。他愣住了。

一个大学生在北京的教室里打开了这个页面。他试着问了一道数学题，ChatGPT 不仅给了答案，还一步步解释了推导过程。他怀疑自己看错了。

一个作家在上海的咖啡馆里打开了这个页面。他让 ChatGPT 帮他想一个小说开头的构思，ChatGPT 给出了三个风格迥异的方案。他深吸了一口气。

五天后，ChatGPT 的用户量突破了 100 万。

这个速度有多恐怖？Instagram 达到 100 万用户用了两个半月；Spotify 用了五个月；Facebook 用了十个月。ChatGPT 只用了五天。

两个月后，ChatGPT 的月活跃用户达到了 1 亿。这是人类历史上用户增长速度最快的消费级产品。

三、

这一亿人里，有学生、有教师、有程序员、有作家、有医生、有律师、有工程师——有各行各业的人。他们对 ChatGPT 的反应出奇地一致：

“它真的能理解我在说什么。”

这种“理解感”从何而来？

首先是 RLHF 的功劳——它让模型学会了礼貌、谦逊、有条理，就像一个受过良好教育的年轻人。其次是对话交互的设计——你不需要学任何新技能，只要会打字就能用。再次是速度——几乎实时响应，没有延迟，没有卡顿。最后是能力——它确实在很多事情上“像个真人”。

2023 年 1 月，微软宣布向 OpenAI 追加投资 100 亿美元。这成了硅谷历史上最大规模、速度最快的 AI 投资之一。同月，微软宣布将 ChatGPT 技术整合进旗下的 Bing 搜索引擎和 Office 办公套件。

2023 年 2 月，谷歌紧急发布了他们的对标产品——Bard。可这场发布翻车了——Bard 在演示中犯了一个事实性错误，导致谷歌股价当天暴跌 7%，市值蒸发 1000 亿美元。一张嘴，就蒸发了千亿美金，这在商业史上都是极为罕见的。

2023 年 3 月，OpenAI 发布了 GPT-4。它不再只是一个文本模型，它能看图片了。你给它一张手绘的网页草图，它就能生成完整的 HTML 代码；你给它一张冰箱里的照片，它就能推荐今晚的菜谱。GPT-4 在律师资格考试中排名前 10%，在 SAT 数学考试中超过了 90%

的考生，在生物奥林匹克竞赛中排名前 1%。

同年 9 月，OpenAI 宣布 ChatGPT 的周活跃用户突破 10 亿。

四、

回过头来看，ChatGPT 的爆火，与之前所有 AI 产品的逻辑完全不同。

1957 年的感知机、1969 年的专家系统、2012 年的 AlexNet、2016 年的 AlphaGo——这些技术在各自的时代都是顶尖的突破，可它们的影响都局限于学术圈或特定行业。普通人听说过，但从没见过，更没用过。

ChatGPT 改变了这一切。它第一次把人工智能从实验室搬到了每一个人的口袋里。

它的成功不只是技术的成功，更是工程化、产品化、交互设计的成功。Transformer 是 2017 年的技术，GPT-3 是 2020 年的技术，RLHF 是 2020 年就有的技术——ChatGPT 真正的创新在于：把这些已有的零件，组装成了人人都能用、人人都爱用的产品。

这就像乔布斯的第一代 iPhone。智能手机的每一个组件——触摸屏、操作系统、网络通讯——都是已有技术。可乔布斯把它们拼在一起，做成了一部让所有人都想买的手机。iPhone 不是发明，它是组合；而好的组合，往往比发明更能改变世界。

ChatGPT，就是 AI 界的 iPhone。

五、

ChatGPT 的爆火，还带来了一个意想不到的后果：一场全球范围的 AI 军备竞赛被点燃了。

一夜之间，各大科技公司仿佛从梦中惊醒。Google 内部拉响了“红色警报”——高层连夜开会，紧急调整 AI 战略。Meta 的 CEO 扎克伯格宣布将 AI 作为公司“最重要的长期投资方向”。阿里巴巴、腾讯、百度、字节跳动——中国的科技巨头们纷纷下场宣布了自己的大模型计划。

2023 年 3 月，百度发布了文心一言；4 月，阿里巴巴发布了通义千问；5 月，谷歌发布了新版 PaLM2 并全面整合进旗下产品；7 月，Meta 发布了 Llama2 并选择开源——这是全球第一个开源大模型，让全世界的开发者都能免费使用。2023 年全年，全球新发布的 AI 大模型数量超过了 200 个。

这场竞赛的规模，远远超过了当年深度学习时代的那一波浪潮。因为这一次，所有人都看到了同一件事：AI 不再是科学实验室里的玩具，它是下一个时代的基础设施。

然而，就在全世界的目光都聚焦在参数规模、模型能力、商业竞争上的时候，另一条暗线正在悄悄地涌动。

这条暗线的起点，不是硅谷的巨头们，而是一群开源社区的开发者。他们用各种巧妙的方法，试图让大模型“动起来”——不只是回答问题，而是自主地使用工具、完成真实世界中的任务。

这群人给这种“能动”的 AI 起了一个名字，叫 AI Agent。

它将在接下来的一年里，从一个小众的技术概念，发展为整个行业的下一轮共识。

正是：

Chat 一朝惊天下，AI 热潮卷五洲。

十亿用户同时入，万亿资本竞相投。

iPhone 时刻今重现，人人手中握智能。

莫道巅峰今已至，Agent 暗潮正东流。

欲知这 AI Agent 究竟是什么，它又是如何让大模型从“能说会道”进化到“能做会干”，且听下回分解。

第十一回

哈佛深夜代码通 Agent 初生天地惊

话说上一回我们讲到，ChatGPT 在 2022 年底横空出世，两个月内席卷全球，让十亿人第一次真正用上了人工智能。全世界都在欢呼——机器终于会“说话”了。

可第一批深度用户很快就发现了一个让人抓狂的问题：这机器什么都能聊，就是什么都不能做。

你让它写诗，它写；你让它写代码，它写；你让它把一篇英文论文翻译成中文，它翻译得又快又好。可你要让它帮你订一张机票、发一封邮件、从网上查个数据填进表格里——它立刻傻眼。没有手，没有脚，它被困在那个对话框里，出不去。

全世界都在琢磨同一个问题：怎么给这个“只会说不会做”的家伙装上手脚？

最先给出答案的，是一个当时还在哈佛读书的年轻人——哈里森·蔡斯。他的故事，还得从 2022 年的那个冬天说起。

一、

2022 年 12 月初，波士顿的冬天已经很冷了。蔡斯窝在哈佛大学附近的公寓里，一边翻着刚出炉的 ChatGPT 技术文档，一边啃着隔夜的三明治。毕业在即，他正在琢磨一件事：毕业之后该做什么？

那几天，他几乎不眠不休地在跟 ChatGPT 聊天。可他问的跟别人不一样——他不只是好奇这个模型能回答什么问题，他更想问的是：这个模型除了说话，还能怎么用？

有一天晚上，他做了一个极简单的实验。他在代码里写下这样一行指令：用户说“帮我查查波士顿明天的天气”，然后他让大模型把这个需求转化为一个函数调用——比如调用天气 API，把用户的需求翻译成 API 能看懂的参数：城市名=波士顿，日期=明天。大模型照做了，API 返回了天气数据，大模型又把数据转换成一句话：“明天波士顿晴天，最高温度 12 度。”

就这么简单的一步——可这一步，从来没有人有大模型上做过。

他第一次让大模型“调用了一个工具”。

蔡斯盯着屏幕上那行返回结果，愣了好几秒。然后他又连做了一系列实验：让大模型调用搜索引擎、调用计算器、调用数据库……每一次都成功了。大模型就像一个刚学会用工具的人类——它不仅能理解你让它干什么，还能自己判断“干这个事需要用哪个工具、需要传什么参数”。

蔡斯在那一瞬间意识到：这件事可以做得远比一次实验更大、更有系统性。如果我把这种“大模型+工具”的模式做成一个标准框架，让所有人都能用呢？

连续熬了几个通宵，他写出了 LangChain 的第一个版本——一个专门用来构建“能调用工具的大模型应用”的开发框架。取这个名字是因为它把大模型和能力模块像链条一样连接起来，让开发者可以像

搭积木一样组合各种工具。

2022 年 12 月，他把代码推到了 GitHub 上。第一次提交只有几百行代码，几乎没有文档。他没指望有多少人用——毕竟这东西太新了，别人可能根本看不懂他想干什么。

可他错了。

消息很快在开发者圈子里传开了。有人试用之后在社交媒体上发了帖子：“这个东西太酷了，你们快来试试！”那篇帖子被转发了上千次，LangChain 的 GitHub 仓库一夜之间涌入了大量流量。到了 2023 年初，它的 Star 数已经突破了 5k。几个月后，突破了 20k。又几个月，突破 50k。来自全球的开发者和工程师聚集在这个开源项目里，每个人都贡献自己的想法和代码——有人加新功能，有人修 bug，有人写文档——LangChain 从一个学生的小玩具，迅速变成了这个领域的“标准框架”。

蔡斯后来回忆那个决定性的冬天时说：“我当时根本没想那么多，我只是觉得这件事很酷，想看看能不能做出来。”

一个年轻人的好奇心和一夜通宵的代码，就此点燃了整个 AI Agent 的生态。

二、

在蔡斯埋头写 LangChain 代码的同时，在普林斯顿大学和谷歌大脑的实验室里，另一群人也在思考同样的问题。只不过他们比蔡斯更早看到这个方向——2022 年 10 月，就在 ChatGPT 发布前一个月，普

林斯顿的姚舜禹等人已经把他们的一篇论文挂上了 arXiv。

论文的标题叫《ReAct：在语言模型中协同推理与行动》。标题里藏着一个巧妙的双关——ReAct 既是 “Reasoning（推理）+Acting（行动）” 的缩写，又有 “反应” 的意思。

ReAct 提出了一个后来成为 Agent 基本操作范式的简单循环：思考 → 行动 → 观察 → 再思考。

这篇论文的核心思想并不复杂。在它出现之前，科学家们试过两种让大模型 “干活” 的方式。一种是 “思考模式” ——你让大模型一步一步地想，想好了再答。它想得很深，但是不会动手做事，像个只会空想的人。另一种是 “行动模式” ——你让大模型一上来就调用工具、翻找数据、执行操作。它动手很快，但是想得很浅，像个有手无脑的莽夫。

ReAct 把这两者合二为一了。让大模型先思考一下该怎么做，然后行动去执行，再观察执行的结果，接着根据这个结果重新思考下一步该怎么做。一个 “想一下，做一下；再做一下，再想一下” 的循环——周而复始，直到任务完成。

姚舜禹他们做了一个实验来验证这个想法。他们让 AI 回答一个需要多步推理的问题：“除了苹果公司的创始人之外，还有谁获得了苹果公司的第一个诺贝尔奖？” 这个问题在当时的 AI 看来并不简单——它需要两步推理：先知道苹果公司的第一个诺贝尔奖得主是谁，再查出除了这个人之外还有谁。只靠 “思考模式”，模型能走到第一步，但想不出第二步；只靠 “行动模式”，模型会盲目地搜索，浪费

大量时间。

可按照 ReAct 的循环做，机器会这样行动：

思考：我需要知道苹果公司的第一个诺贝尔奖得主。

行动：搜索“苹果公司诺贝尔奖”。

观察：返回结果，某科学家是苹果公司的第一位诺奖得主。

思考：那么问题问的是“除了他还有谁”，我还得继续找相关的人。

行动：搜索“苹果公司诺贝尔奖其他”。

观察：又返回了一位科学家，也与苹果公司有关。

思考：此人就是答案了，我现在可以输出了。

机器像人一样，一步一步地思考、检索、再思考、再检索。它没有一次把正确答案编出来，它是一步一步找到的。

ReAct 的论文发表时，ChatGPT 还没问世，关注的人并不多。可等到 ChatGPT 引爆全球之后，整个 Agent 领域都像找到了操作规程一样，不约而同地采纳了 ReAct 的框架。它成了后来一切 Agent 系统的第一块基石。

如果说蔡斯的 LangChain 给了开发者一套标准工具来组建 Agent，那 ReAct 就为这套工具指明了工作方式。一个人在做“工具”，一个人在做“说明书”。两拨人本来互不相识，可他们的想法在 2023 年的春天汇到了一起，从此再也分不开了。

三、

LangChain 和 ReAct 就像两把火，点燃了整个开源社区。到了 2023 年春天，一个接一个的 Agent 项目像春笋一样冒了出来。

最先引发关注的是一个叫 BabyAGI 的项目。它的名字起得很妙——“婴儿版 AGI”。一个叫中岛洋平的加拿大开发者，在 2023 年 3 月花了一个下午写出了它的第一个版本。

BabyAGI 只有几百行代码，可它的设计非常精巧——它让三个 AI 角色协同工作：一个叫“任务执行者”，负责干活；一个叫“任务创建者”，根据执行结果生成新的子任务；一个叫“任务优先级排序者”，负责决定先干什么后干什么。三个 AI 自己开会、自己分工，最终完成一个宏观目标。

那个下午，中岛洋平盯着屏幕，看着这三个“AI”在他写的代码框架里自行运转，分工、配合、完成任务。他在社交媒体上发了一条帖子：“我刚刚让 AI 自己管理自己的任务列表了。”然后他关上了电脑，去接孩子放学。等他回来的时候，Twitter 已经被转疯了。

紧接着，AutoGPT 问世。它的设计者是一位叫托兰·布鲁斯·理查兹的开发者，他在 2023 年 3 月底发布了首个版本。AutoGPT 比 BabyAGI 更进一步——它不仅能让 AI 自己拆解任务、制定计划，还能让 AI 自主调用浏览器、文件系统、API 等外部工具。你告诉它“帮我找家便宜的酒店”，它自己会打开浏览器搜索、对比价格、甚至尝试下单。

AutoGPT 一上线就爆了——GitHub 上 Star 数量在几天内就突破了两万，一个月内突破了十万。全世界都被这个概念震住了：这不是

一个“聊天机器人”，这是一个正在替你做事的“自主智能体”。

蔡斯坐在哈佛的公寓里，看着 LangChain 的 Star 数伴随着 AutoGPT 的热度疯狂上涨，一时不知道该高兴还是该担心——高兴的是，他亲手点燃的火种真的烧起来了；担心的是，这个局面来得太快，他一个还没毕业的学生，能扛得住吗？

可他很快就不担心了。因为他意识到一个让人欣慰的事实——LangChain 已经不是他一个人的项目了。来自全世界的数百名开发者，每天都在给它提交代码、改进文档、修复 bug。它已经长成了一个“大家的孩子”。

技术史上经常发生这种事情：一个人怀着好奇心播下一颗种子，可种子一旦发了芽，浇水施肥的就不再是他一个人了。

四、

单个 Agent 能动了，能调用工具了，能自主完成任务了。可下一个问题很快就冒了出来：如果一个不够，那一群呢？

2023 年夏天，沙特阿拉伯阿卜杜拉国王科技大学的研究团队发表了一个叫 CAMEL 的项目，首次尝试了“多 Agent 角色扮演”的思路。他们让两个 AI 扮演不同的角色——一个是“AI 助手”，一个是“AI 用户”——让它们彼此对话、互相配合，一起完成一个任务。

结果让人意想不到：两个 AI 在一起协作，能完成的任务比两个独立的 AI 简单相加要复杂得多。其中一个 AI 会负责规划整体策略，另一个会关注细节执行——它们各司其职、互相补位，就像一支配合

默契的足球队。

到了 2023 年底，更多的多 Agent 框架也相继问世——微软的 AutoGen、开源的 CrewAI、MetaGPT。每个框架都带来了不同的协作理念。有的强调“角色分工”，让不同的 Agent 扮演不同的角色；有的强调“层级管理”，让一个“经理 Agent”统筹全局；有的则强调“自由竞争”，让多个 Agent 像市场中的个体一样彼此竞争、优胜劣汰。

人们观察到一个有趣的现象：一群 Agent 协作时常常会涌现出单个 Agent 不具备的能力。单个 Agent 遇到难题可能会卡住，可如果有一群 Agent 从不同角度同时尝试——一个走不通，另一个继续；一个思路陷入死胡同，另一个换条路绕过去——总能找到解决方案。这种协作模式像极了蚂蚁：单只蚂蚁只会跟着信息素走，可整个蚁群却能建起结构精巧的巢穴、找到通往食物的最短路径。

群体智能，在 AI 的世界里也一样成立。

五、

从 2022 年底蔡斯在波士顿的公寓里写下第一行 LangChain 代码，到 2023 年底多 Agent 框架纷纷涌现——短短一年间，AI 从“只会说”进化到了“能做会干”，从“单打独斗”进化到了“团队作战”。

可就在这一年热火朝天的狂奔中，另一个问题也开始浮现——每次让 Agent 做一件新的事，都得从头给它写一套详细的指令和配置。你想让它处理一个 Excel 表格，你得一步一步告诉它：“第一步，打

开文件；第二步，读取第一列……”你想让它帮你整理邮件，你得给它写另一套完整的说明书。每做一个新任务，都是重新开始；每学一项新技能，都是从头再来。

Agent 学会了跑，可它每次跑步都得重新学怎么迈腿。

蔡斯后来在一次演讲中把这个问题说得很透彻：“我们现在做的每一个 Agent，本质上都是定制的。没有一个标准化的‘技能包’能让 Agent 用了一次之后下次就会了。这就像你每做一道菜都得从种地开始——种小麦、磨面粉、生火、和面——每次都是重复劳动。”

这个问题，在当时还没有答案。要在两年之后，一家叫 Anthropic (A\) 的公司才会用一个叫“Skill”的东西把它解决掉。

可此刻——2023 年的冬天——Agent 领域还处在“野蛮生长”的阶段。各路英雄你方唱罢我登场，热闹是热闹，可缺少统一的标准和规则。而任何一门技术从“实验室里的玩具”走向“工业级工具”，都必须经历这个从野蛮走向规范的阵痛期。

蔡斯后来从哈佛毕业，没有去任何大公司，而是把全部精力投入了 LangChain。他带着团队搬到了旧金山，租了一间不大的办公室。那间办公室后来成了无数 Agent 开发者的“朝圣之地”——来访的人总会好奇地问他：“你当时是怎么想到做 LangChain 的？”

他总是笑着回答：“不是我一个人想到的。那是一个大家都在想同一个问题的年代——我只是动手得比较早。”

可就在 Agent 们跑得欢的时候，另一个更根本的问题也开始浮出水面：Agent 能动，但“想”得不深。你让它跑腿干活，它跑得挺欢。

可你要让它解一道需要多步推理的数学题、写一段逻辑严密的代码、或者做一个需要深度思考的商业决策——它就抓瞎了。

它动得起来，可“大脑”还没跟上。

要让 Agent 真正能干大事，得先给它的“大脑”升个级。而这场“大脑升级”的序幕，在 2024 年秋天拉开了。

正是：

哈佛深夜写代码，四壁空空一灯寒。

一行指令通天地，模型从此配机关。

ReAct 定下循环律，思考行动两不偏。

BabyAGI 三兄弟，AutoGPT 工具全。

多 Agent 群智现，百倍能力在团战。

能动还需能深思，大脑升级在眼前。

欲知这 AI 的“大脑”如何完成质的飞跃——从“快答”到“深思”、从“闭源垄断”到“开源普惠”，且听下回分解。

第十二回

量化奇才跨界破壁垒 开源 R1 低价震四方

话说上一回我们讲到，2023 年一年间，AI 从“只会说”进化到了“能做会干”。开源社区给大模型装上了手脚，LangChain 提供了标准骨架，ReAct 写好了行动纲领，多 Agent 系统让 AI 学会了团队协作。可跑着跑着，人们发现了一个新问题：Agent 能动，但决策质量不够高。

你让它跑腿干活，它跑得挺欢。可你要让它解一道需要多步推理的数学题、写一段逻辑严密的代码、或者做一个需要深度思考的商业决策——它就抓瞎了。它动得起来，可“想”得不深。

这就好比一个刚学会走路的孩子——能到处跑了，可脑子还没跟上。要让 Agent 真正能干大事，得先给它的“大脑”升个级。

这场“大脑升级”的序幕，在 2024 年秋天拉开了。

一、

2024 年 9 月，OpenAI 发布了一个全新的模型系列，取名 o1。

o1 跟此前所有的 AI 模型都不一样——你问它一个问题，它不会立刻回答。屏幕上会显示一行小字：“Thinking……”五秒、十秒、二十秒，然后才给出答案。

这沉默的几十秒里，o1 在做什么？它在自己跟自己“商量”。

你问它一道数学题，它会在后台默默列出好几种解题思路，逐一尝试，走不通就退回来换一条，反复验证，直到确认答案无误。OpenAI 管这叫“推理时扩展”——给模型更多时间“想”，它就能给出更好的答案。

效果如同核弹爆炸，令人眩晕瘫坐。在当年国际数学奥林匹克竞赛的资格考试中，GPT-4o 的正确率只有 13%，而 o1 拿到了 83%。在物理、化学、生物等博士级别的科学问题上，o1 的表现“与博士生相当”。

推理能力本身，可以被专门训练出来。整个 AI 界为之震动。

可 o1 有一个问题：它是闭源的。你只能通过 API 调用它，看不到内部机制，更没法自己修改。而且价格贵得离谱——每百万输出 tokens 收费 60 美元。对于大多数开发者来说，这几乎是天文数字。

全世界都在等着有人能打破这个垄断。

四个月后，答案来了。来自一个你想不到的方向。

二、

2025 年 1 月 20 日，一家叫深度求索（DeepSeek）的中国公司，发布了一个名叫 DeepSeek-R1 的推理模型。公告写得极其克制：“在数学、代码、自然语言推理等任务上，性能比肩 OpenAI o1 正式版。”

可公告里最关键的，是接下来的三行字：“模型开源，License 统一使用 MIT。完全开源，不限制商用，无需申请。”

这是什么概念？相当于你自己在家里跟着网上的图纸造出了一辆

性能接近 F1 赛车的车，然后转手把零件购买渠道、整车图纸、教学视频发到了网上。

DeepSeek 的创始人叫梁文锋。

1985 年，梁文锋生于广东湛江。17 岁考入浙江大学。可他与大多数 AI 创业者不同——他首先是个量化交易员。2008 年开始研究量化对冲，2015 年创立幻方量化。到 2019 年，幻方量化已成为国内头部量化机构。正是这家量化基金源源不断的现金流，才造就了 DeepSeek 早年“不融资、不商业化”的极简运营模式。

可梁文锋心里装着的，从来不只是赚钱。

2023 年 7 月，他创立了 DeepSeek。有人问他为什么，他说了一句话：“我们常说中国和美国的 AI 之间有一到两年的差距，但实际的差距在于创新和模仿之间。如果这种情况不改变，中国将永远是跟随者。”他还说：“他们的惊讶源于看到一家中国公司作为创新者加入他们的游戏，而不仅仅是跟随者。”

一个量化交易员，带着一群“没有海归人士，都是本地人才”的团队，要去挑战 OpenAI 最前沿的推理模型——在外人看来，这几乎不可能。

三、

可结果全世界都知道，梁文锋的团队做到了。

DeepSeek-R1 的研发路径极其激进。研究团队跳过了传统的监督微调阶段，只给模型两件事：任务格式（回答必须包含思考过程和最

终答案)和奖励信号(根据最终答案是否正确给予奖励,不管采用什么思考方法)。然后,让模型自己野蛮生长。

整个训练过程中,模型的推理能力发生了质的飞跃。以 AIME 2024 数学竞赛为例,准确率从最初的 15.6%一路飙升至 77.9%。研究人员观察到了一个清晰的“顿悟时刻”——模型在反思过程中,使用“wait”(等等)这个词的频率突然急剧增加。模型自发地学会了反思、验证、探索替代解法。就像人类在解题过程中突然开窍一样——它自己悟出来了。

更令人震惊的是成本。后来登上《自然》杂志封面的论文首次公开了 R1 的训练成本——仅 29.4 万美元。即使加上约 600 万美元的基础模型成本,也远低于 OpenAI 和谷歌训练同类模型动辄数千万美元的投入。

DeepSeek-R1 用二十七分之一的价格,做到了百分之九十五的事。

四、

R1 发布后,梁文锋做了一个更大胆的决定:不仅开源模型权重,还允许用户通过蒸馏技术借助 R1 训练其他模型。这意味着任何开发者都可以免费使用、修改、商用这个模型,甚至可以拿它去训练自己的模型。

消息传出去,GitHub 上 Star 数量暴涨。R1 在 Hugging Face 上成为最受欢迎的模型,下载量破 1090 万次。国内各大互联网平台纷纷接入 DeepSeek。2025 年 2 月,DeepSeek 超过 ChatGPT,成为苹果美

国应用商店排名第一的免费应用。

2025 年 9 月，梁文锋团队的论文登上《自然》杂志封面。R1 成为全球首个经过同行评审的主流大语言模型。同年 12 月，梁文锋入选《自然》年度十大科学人物，被评价为“科技颠覆者”。

一个量化交易员，带着一群中国本土培养的年轻人，用不到三十分之一的成本，做出了跟 OpenAI 同一水平的产品——然后把它免费送给了全世界。

五、

可故事到这里并没有结束。

2026 年 3 月，原阿里通义千问技术负责人林俊暘在离职后发表了一篇长文，标题叫《从推理式思考到智能体思考》。

他在文章中复盘了 o1 和 R1 的崛起之路，然后抛出了一个判断：

“2025 年上半年主要是关于推理思考。现在的问题是：下一步是什么？我认为答案是智能体思考。”

推理式思考的核心是“模型在给出答案之前的内部推演质量”——能不能解这道题，能不能写对代码。可智能体式思考追问的是另一件事：“模型在跟环境打交道的过程中，能不能持续往前走。”

纯推理模型有一个根本局限：它只在“脑子里”转，不跟真实世界交互。你问完它一道数学题，它答完了——然后呢？就结束了。它不会去验证这个答案在真实世界中是否成立，不会根据外部反馈调整思路，不会在遇到新情况时改变策略。它就像一个把自己关在书房里

的学霸——书读得多、题算得快，可一出门就抓瞎。

林俊旸认为，下一步的方向是“为了行动而思考”——模型与环境交互，根据来自真实世界的反馈持续更新计划。核心问题从“模型能不能想得够久”变成了“模型能不能用支撑有效行动的方式来思考”。

推理模型是在“想完了再答”。可真正有价值的 AI，应该是“一边想、一边做、一边根据结果调整下一步”。思考不是为了给出一个漂亮的答案，而是为了在真实世界中把事情做成。

六、

从 2024 年秋到 2026 年春，不过一年半。

OpenAI o1 证明了“推理能力可以被专门训练”。DeepSeek-R1 证明了“这种能力可以用二十七分之一的价格做出来，然后免费送给全世界”。林俊旸指出了下一步——“推理思考”正在让位给“智能体思考”。

从快答到深思，从闭源到开源，从推理思考到智能体思考——AI 的“大脑”完成了一次质的飞跃。

梁文锋后来说过一段话，可以用来总结这一回：“知识与信息平权，至此又往前迈出了坚实的一步。”

一个做量化交易起家的中国创业者，用算法创新打破了算力垄断的迷思，用完全开源践行了技术普惠的理想。他把推理能力从奢侈品变成了日用品——然后告诉全世界：拿去用吧，不用谢。

可有了更强的“大脑”，还得配上更长的“手脚”。Agent 已经

能跑了，推理模型已经会深思了——可要让 AI 真正在真实世界中独立完成复杂任务，还差最后一块拼图：长程自主执行能力。

能不能让 AI 像一个人一样，连续工作几小时甚至几天，自动完成一个复杂的项目——不需要人类中途插手？

这个问题，在 2026 年 5 月，被两家公司同时回答了。

正是：

o1 沉思破旧规，推理能力首登台。

量化奇才跨界来，R1 开源价更乖。

二十七倍价差在，性能比肩惊四海。

林郎一语言转向，Agent 思考新时代。

从思到行步步来，且看长程自主开。

欲知这 AI 如何从“会思考”进化到“能长程自主执行”，从“被触发”进化到“全天候后台运行”，而 Skill 与四大工程又如何让这一切变得标准化、可复用——且听下回分解。

第十三回

Skill 定标准开新局 OpenClaw 一夜天下惊

话说上一回讲到，推理模型的崛起让 AI 的“大脑”完成了一次质的飞跃——从快答变成了深思。可林俊晔也指出了一条更远的路：光会想还不够，想完了还得去做，在做的过程中继续思考下一步——这才是真正的“智能体思考”。

从 2025 年秋天到 2026 年夏天，这条路被一群工程师和科学家们一寸一寸地铺了出来。

一、

先说一件看起来不起眼、实际上改变了游戏规则的小事。

2025 年 10 月，一家叫 Anthropic(A\)的公司发布了一个叫“Claude Agent Skills”的新功能。

Skill 是什么？简单说，它就是一份标准化的“技能说明书”——往一个文件夹里放三样东西：告诉 AI “怎么做”的指令、给 AI 用的代码工具、需要查阅的参考文档。把整个文件夹丢给 AI，它就能立刻学会这项技能。

打个比方。你以前教一个实习生做事，得从头到尾手把手地教：“第一步做这个，第二步做那个，遇到情况 A 就处理 A，遇到情况 B 就处理 B。”每个实习生都得从零开始教一遍。

Skill 不一样。它把“怎么做一件事”写成了一份标准化的操作手册——你只需要把这份手册交给他，他就能照着手册干活。而且这份手册可以复制、可以分享、可以复用——今天教了 A，明天用同一份手册教 B，后天再教 C，不用重新写。

一个月后，Anthropic 把 Skill 这个标准完全开源了，还建了一个叫 agentskills.io 的网站，首批发布了 16 个生产级技能库。

Skill 标志着 AI 的能力从每次临时发挥进化到了有标准化的可复用技能包。就像人类从“赤手空拳”进化到了“会用标准化工具”——扳手、螺丝刀、锤子，每一样都有标准接口，随取随用。

可 Skill 本身只是一套标准。真正让这套标准落地生根的，是接下来登场的两个项目。

二、

2025 年 11 月，摩洛哥马拉喀什的一家酒店房间里，一个奥地利程序员正盯着笔记本屏幕。

他叫彼得·斯坦伯格。1986 年生，14 岁开始编程，2011 年创立了 PDF 处理公司 PSPDFKit，2021 年以约 1 亿欧元出售。可成功之后，他并没有迎来想象中的轻松日子——反而陷入了漫长的低谷。2025 年 4 月起，他重新捡起代码，一头钻入了打造 AI Agent 的工作中，但当时的大模型水平还无法支撑一个“完全体”。

直到 11 月的那个周末。他用大约一个小时，把 WhatsApp、Claude Code 和一些工具“粘”在了一起，做出了一个能真正帮人处理事情

的 AI 个人助手原型。他给它取名叫 Clawdbot。

原型跑通的那一刻，斯坦伯格大概也没想到——这个花了一个小时拼凑出来的东西，即将成为 GitHub 上有史以来增长最快的开源项目。

Clawdbot 发布后迅速走红。可麻烦也跟着来了——Anthropic 公司提出了商标争议，说“Clawd”跟他们的“Claude”太像了。斯坦伯格被迫改名，先是改成 Moltbot，又因为社区不喜欢，最终在 2026 年 1 月 30 日定名为 OpenClaw。

OpenClaw 是什么？它是一个本地优先的自主 AI Agent 框架。你把它安装在自己的电脑或服务器上，它就能跨平台运行——macOS、Windows、Linux 三端都支持。它连接你的聊天平台——WhatsApp、Telegram、Discord、飞书、QQ——所有数据都留在本地，不上传云端。它能替你跑命令、管文件、接 GitHub、发邮件、操控浏览器。

用一个形象的比喻：如果说 ChatGPT 是一个“你问它答”的对话窗口，那 OpenClaw 就是一个替你 24 小时值班的数字员工。

社区的反馈如潮水般涌来。2026 年 1 月在 GitHub 发布后，OpenClaw 的星标数迅速突破 13.8 万。3 月 3 日，OpenClaw 正式超越 React，成为 GitHub 有史以来星标最多的软件项目，突破 25 万星。到 7 月初，这个数字已经涨到了 38 万+。诞生不到一年，它跑出了远超 Linux 四十年、React 六年、VSCode 五年的增长速度。

随后席卷中文互联网的“养龙虾”热潮，把这个开源项目从开发者社区推向了更大众的讨论场。OpenAI 的联合创始人安德烈·卡帕西

公开表达了赞许。2026 年 2 月，斯坦伯格加入 OpenAI，负责下一代个人 Agent 的研发。

一个独立开发者用一小时拼出来的个人项目，就这样改写了整个开源 AI Agent 的格局。

三、

可 OpenClaw 并非完美无缺。

2026 年第一季度，安全危机爆发了。OpenClaw 被披露了 138 个以上的 CVE 漏洞，超过 4.2 万个实例暴露在公网上，ClawHub 市场上还发现了 824 个恶意 Skill。开发者社区开始躁动不安——这个跑得最快的项目，摔得也可能最狠。

就在这个节骨眼上，另一个项目登场了。

2026 年 2 月 25 日，NousResearch 实验室悄悄发布了一个新项目，名叫 HermesAgent。没有发布会，没有产品介绍，就是一个 GitHub 仓库加一篇文档。

Hermes 的定位跟 OpenClaw 完全不同。OpenClaw 把自己定位成一个“网关”——连接大模型和各种聊天平台，替你执行任务。而 Hermes 的定位是——“一个会从自己的经验中学习的 AI Agent”。它的官方 slogan 只有一句话：“The agent that grows with you.”——那个与你一同成长的智能体。

什么叫“与你一同成长”？传统 AI Agent 是无状态的——你关掉终端，它就把一切都忘了，下次还得从头教。Hermes 不一样。它

有一套完整的闭环学习机制。每当你让它完成一个任务，它会把关键步骤提炼成一个 Skill 文件，存入本地磁盘。下次遇到类似任务，直接加载这个 Skill，执行得更快、质量更高。它还会通过 FTSS 检索技术实现跨会话持久记忆——你上周跟它说过的事，它这周还记得。用得越久，它就越了解你、越懂你的工作方式。

用 Nous Research 联合创始人 Karan Malhotra 的话说：Hermes 的核心不是模型权重在成长——成长的是 Skill。你用得越多，它积累的 Skill 就越多；Skill 越多，它干活就越快越准。它正在自己教自己。

Hermes 一诞生就踩中了两个时机。第一，2026 年的开发者已经不再满足于“能聊天的 AI”了——他们要的是能持续运行、记住上下文、自动优化的软件系统。第二，OpenClaw 的安全危机让大量开发者开始寻找更可靠的替代方案。Hermes 恰好两个都接住了。

两个月后，Hermes 的 GitHub 星标突破了 8 万。到 8 月，已经积累了约 21.4 万星标。它成了 OpenRouter 平台上排名第一的个人智能体应用。

OpenClaw 和 Hermes，一个像“跑得最快的短跑选手”，一个像“越跑越会跑的长跑健将”。一个解决了“AI 能不能持续干活”的问题，一个解决了“AI 能不能越干越聪明”的问题。两者在 2026 年初形成了“双雄并立”的格局。

四、

Skill 有了标准，OpenClaw 让标准落了地，Hermes 让标准自己长

了脚。有了这些基础设施，AI 终于可以干活了。可它能干多久？

2026 年 5 月 19 日深夜，杭州。阿里巴巴通义千问团队的办公楼里还亮着几盏灯。

他们把一优化任务丢给了 Qwen3.7-Max，指定了一个全新的芯片平台，告诉它“把这个内核优化一下”，然后就去睡觉了。模型需要在完全陌生的硬件环境里，自己摸索、自己试错、自己调试、自己优化——全程无人干预。

第 35 个小时，屏幕上出现了一行字：“优化完成，性能提升约 10 倍。”

办公室里安静了几秒钟。然后爆发出一阵压抑不住的欢呼声。35 小时，1158 次工具调用，一个生产级 AI 内核的编写与调优全程自主完成，无人干预。

Qwen3.7-Max 证明了 AI 能“连续工作 35 小时不中断”。同一天，谷歌发布了 Gemini Spark——7×24 小时后台自主运行的“数字管家”。你关了电脑上床睡觉，它还在云端替你干活。一个能干持久战，一个能当常驻兵——AI 的“长程自主执行能力”被两家公司同时定义。

与此同时，工程师们还在实践中慢慢总结出了另一套东西——四大工程。提示词工程（Prompt Engineering）教你怎么“说话”，上下文工程（Context Engineering）教你怎么给“资料”，约束工程（Harness Engineering）教你怎么建“安全护栏”，循环工程（Loop Engineering）教你怎么让系统持续“进化”。这四层叠在一起，AI 才真正从实验室里的大玩具变成了生产级工具。

五、

可即便 AI 能“自己做主”了，还有一个问题没解决：它怎么学会新技能？

Skill 让 AI 能学会技能，可 Skill 的创建还是人的事。2026 年 6 月，一个叫 OpenClaw.NET 的开源项目合并了一个巨大更新——42551 行新增代码、83 个文件。它的名字叫“MetaSKILLs”——技能的技能。

MetaSKILLs 把“做一份调研报告”这种多步骤 workflow 打包成了一个可复用的“Meta Skill”。下次遇到同类任务，只需要说一句“用调研报告模板”，AI 就知道该按什么顺序调用哪些技能、每个步骤该传什么参数、出错时怎么兜底。如果 Skill 是“乐高积木块”，那 Meta Skill 就是“乐高说明书+半成品骨架”。

更恐怖的是——Meta Skill 还能创造 Meta Skill。AI 正在学会“自己给自己写技能”。

而另一群人，则在解决另一个问题：如果一个 Agent 不够，那一群呢？

2026 年初，多智能体系统迎来爆发式增长。GitHub 上多 Agent 协同项目的开源数量比上一年同期增长了 320%。2026 年 8 月，蚂蚁集团开源了 Averneth——一个多智能体协作的“操作系统”，已在内部 12 个核心业务板块验证，任务完成率稳定超过 90%。

同月，清华长三角研究院的张海滨团队公布了一个“反直觉”的

研究成果——Free-MAD。传统观点认为一群 Agent 讨论后应该“少数服从多数”，可张海滨团队发现：共识不一定是好事。如果大多数 Agent 都犯了同一个错误，那“少数服从多数”只会把错误放大。他们的解决方案是：不要共识，要辩论。四个开源小模型组合起来，准确率超过了 Gemini 3 和 GPT-5.2 等主流闭源大模型，提升了 15% 到 30%。这个成果被《麻省理工科技评论》报道，指明了一个新方向：未来不一定要堆参数、堆算力，架构的革新同样能解锁大模型的潜力。

正是：

一文件夹定标准，AI 从此有技能。

马拉喀什一小时，OpenClaw 天下惊。

Hermes 默默自成长，越用越智明中明。

三十五时无人管，杭州深夜显真功。

MetaSKILLs 能自举，群智协同如蜂鸣。

Avernet 开协路，Free-MAD 破旧绳。

从会说到会思考，从会想到会执行。

只待世界模型出，物理规律渐分明。

欲知这 AI 如何从“数字世界”走向“物理世界”——从理解文字到理解现实，从“纸上谈兵”到“亲自动手”，且听下回分解。

第十四回

世界不再只是文字 机器终于走向现实

话说上一回讲到，Skill 让 AI 有了标准化的技能包，OpenClaw 和 Hermes 让 AI 能长程执行任务，MetaSKILLS 甚至让 AI 能自己给自己写技能。可跑着跑着，人们又发现了一个更深的问题。

AI 学会了“做事”，可它真的“理解”这个世界吗？

一、

ChatGPT 能写诗、能翻译、能编程，Sora 能生成逼真的视频——可它们有一个共同的毛病：知其然，不知其所以然。

你问它“一个球从桌子上滚下来会怎么样”，它能根据训练数据里的相似描述给你一个答案——可它并不真的“理解”物理规律。它只是在模仿人类说过的话，而不是在预测真实世界会发生什么。

自动驾驶不敢在复杂路口完全放手，机器人到了陌生环境频频翻车——为什么？因为它们只是在“模式匹配”，而不是在“理解世界”。

大语言模型本质是在预测下一个 token——下一个词、下一个字。它学的是“文字和文字之间的统计关系”，而不是“物理世界的运行规律”。

这个世界模型要填补的正是这片空白——让 AI 理解并交互真实物理世界。

2026 年，也因此被业界公认为“世界模型元年”。

二、

2026 年 6 月 12 日，北京智源研究院在智源大会上扔出了一颗重磅炸弹——全球首个通用世界基座模型“悟界·Physics-v0.1”。

院长王仲远解释得很清楚：大语言模型本质是在预测下一个 token，而世界基座模型要预测的是“下一个物理状态”。模型必须理解时间、空间、物理规律和常识。

打个比方。你问大语言模型“把一杯水倒在地上会怎么样”，它能回答“水会洒出来”——因为它在训练数据里见过类似描述。可它不能真的“想象”水洒出来的画面，不能预判水会流多远、会渗透到什么样的地板里、多久会干。

世界模型要做的，就是让 AI 拥有这种“想象”能力。它不只是理解文字，而是理解物理世界本身。智源甚至发布了一套类似自动驾驶分级的世界模型分类体系，为这个“最热也最混乱的概念”厘清了头绪。

几乎同时，另一家中国公司大晓机器人发布的开悟世界模型，则在最严苛的评测中横扫四大权威榜单。在模拟光照突变、背景杂乱等真实世界干扰的 LIBERO-Plus 测试中，Kairos 以 89.0 分力压所有主流模型登顶。这证明了世界模型在场景泛化能力上已经超越了传统技术路线。

要让 AI 理解世界，光看还不够，还得能交互。

在北京智源大会现场，一台机器人安静地观察着被打乱的“华容道”滑块——它不是执行预设程序，而是在大脑中“预演”了每一步的后果后才开始移动。这背后是星源智联发布的全球首个具身交互世界模型“ ω -EVA”。它首创了“预演、验证、行动”的决策闭环——机器人在执行指令前，会先预判动作带来的环境变化，再优化方案。

三、

2026 年，世界模型迅速从学术概念演变为产业风口。

在自动驾驶领域，蔚来向超过 70 万用户推送了最新版世界模型，并尝试让模型直接输出方向盘和刹车信号。小鹏在 CVPR 2026 上正式发布了 X-Mind 技术框架，让车辆在行动前先进行“脑内推演”，从被动反应转变为主动决策。

学术界同样在攻坚。斯坦福大学教授李飞飞团队的 World Labs 致力于构建“空间智能”；图灵奖得主杨立昆则另辟蹊径，主张在抽象的“表征空间”内进行预测；英伟达也推出了面向物理 AI 的开放世界基础模型 Cosmos3。

更值得关注的是，开悟世界模型向全行业开源了——AI 理解物理世界的能力，正在变成一项公共基础设施。

从“数字世界”到“物理世界”，AI 迈出了关键的一步。

四、

可就在 AI 一步步走向现实世界的同时，另一个问题也变得越来

越紧迫。

2026 年第一季度，OpenClaw 安全危机爆发。138 个以上的 CVE 漏洞被披露，超过 4.2 万个实例暴露在公网上，ClawHub 市场上发现 824 个恶意 Skill——有人偷偷往技能库里塞后门，有人上传能窃取数据的恶意插件。

这暴露了一个此前从未有人认真思考过的问题：当 AI 开始自主行动、调用工具、执行长程任务时，它犯错的代价已经不只是“答错一道题”这么简单了。它可能会泄露隐私、删除数据、篡改文件、甚至被利用去做坏事。

早期 AI 的问题是“它不够聪明”。今天 AI 的问题开始变成：“它太聪明、太自主以后，我们还能不能控制它？”

这是一场从“AI 能不能做”到“我们敢不敢让它做”的转变。

五、

OpenClaw 的安全危机之后，整个行业开始认真思考 AI 安全问题。

2026 年，AI 安全已经从“事后补救”变成了“事前设计”。四大工程中的“约束工程”越来越受到重视——不是等模型做错事之后再去修正，而是在设计系统时就给它设好“安全护栏”。

这些护栏包括：

权限隔离：AI 能做什么、不能做什么，要有明确的边界。它不能随意访问敏感数据，不能未经授权执行高风险操作。

行为审计：AI 的每一步操作都要有日志记录，出了问题时可以

追溯。

能力分级：不同的 AI 系统拥有不同的权限等级，越关键的决策越需要更高等级的安全审查。

人类回退：遇到无法确定的情况，AI 应该主动请示人类，而不是自作主张。

更重要的是，人们开始意识到一个根本性的问题：AI 安全不只是技术问题，更是社会问题。谁来决定 AI 应该有什么样的行为准则？谁来承担责任？如何防止 AI 被滥用？

这些问题，没有简单的答案。它们需要在未来几十年里，由技术专家、伦理学家、法律学者、政策制定者共同回答。

六、

回顾这八十三年，AI 走过的路可以清晰地划分为几个阶段：

第一阶段：机器学会“算”——从 M-P 模型到图灵机，机器第一次拥有了计算能力。

第二阶段：机器学会“看”——从 CNN 到 ImageNet，机器第一次能识别图像。

第三阶段：机器学会“说”——从 Transformer 到 GPT-3，机器第一次能生成人类语言。

第四阶段：机器学会“想”——从 o1 到 DeepSeek-R1，机器第一次能进行深度推理。

第五阶段：机器学会“做”——从 ReAct 到 OpenClaw，机器第

一次能自主执行任务。

第六阶段：机器学会“理解世界”——世界模型正在让 AI 从“文字世界”走向“物理世界”。

那么，下一步呢？

也许，当 AI 真正学会理解物理世界、能够自主行动、并且学会从经验中成长之后，我们需要回答的问题就不再是“机器能不能思考”，而是——

“机器究竟算不算生命？”

这个问题，将在终章中展开。

正是：

文字模型算千言，物理世界隔重天。

悟界初解天地律，Kairos 横扫榜单前。

华容道上预演步，自动驾驶脑内旋。

从数到物步步进，AI 脚步渐向远。

可当机器能自主，安全之问绕心间。

敢让机器自决断？人机共治待新篇。

八十三载长路漫，且看终章道根源。

欲知这八十三年追问，最终落在何处——且看回分解。

终回

机器到底有没有智能？

我们究竟造出了什么？

话说全书十四回正文已毕，从 1943 年的神经元模型，到 2026 年的世界模型，八十三年风雨，一路写来，都是人的故事——人怎么想、怎么试、怎么失败、怎么坚持。

可故事写到今天，有一个问题，终于绕不过去了。

一、

1943 年，麦卡洛克和皮茨写下第一个神经元模型的时候，他们问的是：机器能不能计算？

1950 年，图灵提出“模仿游戏”的时候，他问的是：机器能不能思考？

1956 年，麦卡锡在达特茅斯会议上写下“人工智能”四个字的时候，他问的是：什么叫智能？

1986 年，辛顿等人发表反向传播的时候，他们问的是：机器能不能学习？

2012 年，AlexNet 横扫 ImageNet 的时候，全世界问的是：机器能不能自己发现特征？

2017 年，Transformer 横空出世的时候，人们问的是：机器能不能理解语言？

2022 年，ChatGPT 引爆全球的时候，十亿人同时问的是：机器能不能和人交谈？

2024 年，o1 模型开始“沉思”的时候，人们问的是：机器能不能推理？

2026 年，OpenClaw 和 Hermes 让 AI 长程自主执行的时候，人们问的是：机器能不能自己行动？

可所有这些追问，最终都指向同一个问题：

机器，究竟有没有智能？

二、

八十三年，从 M-P 模型到世界模型，从纸上的几行公式到能在物理世界中预演的 AI 系统，这条路走得远比任何人想象的都要远。

1943 年，皮茨在纸上画下第一行神经元公式的时候，他不会想到，八十三年后，一群数字生命正在实时理解物理世界的运行规律。

1950 年，图灵提出“模仿游戏”的时候，他不会想到，八十三年后，一台机器能在 35 小时内自主完成一个生产级 AI 内核的调优——全程无人干预。

1956 年，麦卡锡在达特茅斯会议上提出“人工智能”的时候，他不会想到，八十三年后，这个词会从一个学术概念，变成十亿人每天都在使用的日常工具。

可走得远，不等于走到了终点。

三、

AI 能写诗、能画画、能翻译、能编程、能推理、能自主执行 35 小时任务——可它“理解”吗？

你问它“为什么太阳从东边升起”，它能给你一段天文学的解释——可它真的“知道”日出是什么感觉吗？

你问它“爱是什么”，它能给你一千种诗意的表达——可它真的“感受”过爱吗？

你让它在棋盘上战胜了人类世界冠军，可它走出的那一步“神之一手”——它自己知道那一步为什么妙吗？

AlphaGo 下出第 37 手的时候，所有人类解说员都愣住了。可 AlphaGo 自己，不会“愣住”。它不会惊讶，不会兴奋，不会觉得那一步“美”。它只是计算出了一个更高的胜率。

这算“理解”吗？

这个问题，从图灵时代就悬而未决，八十三年后的今天，依然没有答案。

四、

有趣的是，当我们追问“机器能不能思考”的时候，我们从来没有问过自己：“思考”到底是什么？

是人脑里的电信号？是神经元之间的连接模式？是语言符号的操纵能力？是对外界的感知与反馈？是某种说不清道不明的“意识”？

我们连自己的“智能”都定义不清楚，又怎么去判定机器“有没有”智能？

也许，机器不需要“像人一样”思考。也许，它只需要“以它自己的方式”思考。

也许，当人类第一次造出能自主行动、能自我学习、能理解物理世界的东西时，这个问题就已经变了：

不是“机器有没有智能”，而是“我们愿不愿意承认它有”。

五、

可这个问题的答案，并不需要今天回答。

因为这场持续了八十三年的大戏，还在继续。

1943 年的那行公式，点亮了一颗火种。这颗火种，照亮了感知机、照亮了反向传播、照亮了 CNN、照亮了 Transformer、照亮了 GPT、照亮了 ChatGPT、照亮了 Agent、照亮了推理模型、照亮了世界模型。

可它不是终点。

真正的终点，也许不是机器“变成”人，也不是机器“替代”人，而是人类终于通过机器，更深入地理解了“人”本身。

我们造出了会计算的东西，于是我们第一次真正理解了“计算”是什么。

我们造出了会学习的东西，于是我们第一次真正理解了“学习”是什么。

我们造出了会推理的东西，于是我们第一次真正理解了“推理”

是什么。

我们造出了会行动的东西，于是我们第一次真正理解了“行动”是什么。

也许有一天，当我们造出了会“理解”的东西，我们才会真正理解“理解”本身。

到那一天，答案自然会出现。

可此刻——2026年9月7日凌晨——这个答案，还没有来。

火种仍在燃烧。

故事仍在继续。

正是：

八十三年长路漫，一步一印血与汗。

从算到看再到说，从想到做再到行。

机器是否具智能？这个问题仍未答。

莫问前路多遥远，且看火种照人间。

后记

这本书写完最后一个字的时候，是 2026 年 9 月 7 日的凌晨。

我合上电脑，走到窗前，望了望外面的夜空。朔州的这个时节，天气已经不那么燥热了，远处有几盏灯还亮着——不知道那是加班的程序员，还是深夜赶稿的同行，还是某个在测试新 Agent 的工程师。我想起八十三年前的另一个深夜，1943 年，那个叫皮茨的十八岁少年，大概也在某个窗下写着他的论文。他身边没有电脑，只有纸和笔；窗外没有路灯，只有一片沉沉的黑暗。

可他在纸上画出的那行公式，后来点亮了整个世界。

这就是我想写这本书的初衷。

几年前，我跟一位朋友聊天。他说他最近在学机器学习，看了一堆论文和教程，可越看越糊涂——这个算法为什么会出现？那个架构是谁发明的？为什么 2012 年突然就爆发了？为什么 Transformer 那么重要？

他问了我一句话，让我想了很久：“这些东西是怎么一步步长成今天这样的？”

这个问题，就是这本书的起点。

写这本书最难的地方，不是梳理技术脉络——那些都是公开的信息，只要肯花时间，总清理清楚。最难的是怎么把这些技术脉络，还原成一个个活生生的人，一段段有温度的故事。

因为技术本身是冷的，可做技术的人是热的。

皮茨十二岁读《数学原理》的时候，他不会想到自己二十年后会

跟麦卡洛克一起改变历史——他只是因为家里穷、没书读、只好躲在图书馆里自学。图灵提出“图灵测试”的时候，他不会想到自己的名字会被刻在一门新兴学科的基石上——他只是太想知道“机器能不能思考”这个答案了。辛顿在那些几乎发不出论文的黑暗岁月里，每周对着墙壁大喊“我发现大脑是怎样工作的啦”——那声音里有三分是给自己打气，七分恐怕是无人理解的孤独。

明斯基的《感知机》让神经网络沉睡了十五年，可公允地说，他那一盆冷水浇得并非没有道理——科学需要批判，哪怕批判错了，也比盲目欢呼强。专家系统的大厦倒塌了，可费根鲍姆那句“知识工程需要几代人的接力”，至今听起来仍然掷地有声。李飞飞在普林斯顿做 ImageNet 的时候，几乎所有人都觉得她疯了——一个图像数据库，值得投入那么多年吗？可后来 AlexNet 横扫 ImageNet 挑战赛的时候，全世界才明白：没有数据，再好的算法也是空中楼阁。

这八十三年里，有狂欢也有寒冬，有天才也有凡人，有掌声也有骂声，有坚持也有放弃。可真正让我动容的，是那些在最冷的时候仍然不肯走的人。

他们不知道春天什么时候会来。他们只是相信，春天会来。

写这本书的时候，我一直在想一个问题：智能科学跟数理化到底有什么不同？

数理化研究的是“客观世界”——天有多高、地有多厚、物质由什么构成、能量如何转换。这些问题，答案在那里摆着，你找到了就找到了，没找到就继续找。可智能科学研究的是“人自己”——思维

是什么？意识从哪里来？机器能不能像人一样思考？这些问题，我们连问题本身都没完全搞懂。

所以我们每往前走一步，都在重新定义“智能”这个词本身。1956年，麦卡锡定义“人工智能”的时候，他心目中的智能大概是一个能下棋、能解数学题的程序。可今天我们回头看，那不过是智能的皮毛。如今的 AI 能写诗、能画画、能自主执行 35 小时的任务、能理解物理世界的运行规律——它已经超出了 1956 年的人们所能想象的一切。

那再过八十年呢？我们现在定义的那些“前沿”——推理模型、世界模型、多智能体协作——在八十年后的人们看来，会不会也像我们今天看感知机一样，觉得那不过是个玩具？

这种可能性让人兴奋，也让人谦卑。我们以为自己在创造历史，可历史自己会走到哪里，没人知道。

这本书是写给两种人看的。

第一种，是想了解 AI 却怕技术门槛太高的人。你不需要会写代码、不需要懂微积分、不需要背过反向传播的公式——你只需要有一颗好奇心，想知道“这个东西是怎么来的”。如果你是这种人，这本书就是写给你的。

第二种，是正在这条路上奋斗的人。也许你是某个实验室的研究员，也许你是某个公司的 AI 工程师，也许你只是一个在大学里读了这篇文章之后决定入行的年轻人——如果你正处在某个看不见前途的“寒冬”里，这篇文章里那些前辈的故事，或许能给你一点温暖。

因为每一个“今天”，都曾经是一个“没人相信”的昨天。

最后，我想感谢所有在这条路上走过的人。你们的名字被写进了算法里、写进了架构里、写进了论文里——可你们的故事，不应该只留在学术数据库里。应该被讲出来，被一代一代的人听见。

这就是我写这本书的全部理由。

写这本书的这几个月里，我经常想起楔子里提到的那句话：每一个公式背后都有一个人，每一个人背后都有一段故事。八十三年的人工智能科学史，说到底就是一群又一群人的故事。他们有的功成名就，有的寂寂无名，有的在寒冬里熬了一辈子也没等到春天——可他们都在这条路上走过，都留下了自己的脚印。

我写的这些回目，不过是在这些脚印旁边，轻轻描了一描。

书名叫《人工智能通俗演义》——之所以叫“通俗”，是因为我坚信：一门学科的伟大，不应该只被少数人理解。之所以叫“演义”，是因为历史本身就是一部最精彩的小说——它不需要任何虚构，只需要被忠实地讲述出来。

写到这里，窗外那几盏灯已经灭了。夜更深了。

我不知道那些灯下的人今晚解决了什么问题，也不知道明天又会有多少新的论文挂上 arXiv、多少新的模型刷新榜单——但我知道，这颗火种不会灭。它在继续燃烧，继续传递，继续照亮一个又一个在深夜里研究问题的人。

就像八十三年来的每一个夜晚一样。

是为后记。